

AFI - Global Education

**Máster Executive en Data Science, Big Data e
Inteligencia Artificial**



Trabajo Fin de Máster

**Estudio del comportamiento de los viajes en
servicios de vehículos de transporte con
conductor en Nueva York mediante ciencia de
datos**

**Autor: Gonzalo López Segovia
Tutor: José Manuel Rodríguez**

Mayo 2025

1 Resumen

En este trabajo se analizan los viajes realizados por servicios de vehículo de alquiler con conductor (*high-volume FHV*) de la ciudad de Nueva York, con el objetivo de segmentar el comportamiento de los viajes y generar modelos de predicción para estimar la remuneración de los conductores. A partir de los datos proporcionados por la Taxi and Limousine Commission (TLC) de Nueva York, se aplican técnicas de ciencia de datos como el análisis exploratorio (EDA), los algoritmos de clustering no supervisado y los modelos predictivos tanto paramétricos (regresión lineal) como no paramétricos (árboles de decisión). Dada la gran cantidad de datos disponibles, se recurre a modelos de inferencia estadística para hacer frente a los requerimientos computacionales. Los modelos obtenidos se evalúan a partir de las métricas de validación ordinarias (R^2 , MAE, MAPE), que muestran una capacidad predictiva satisfactoria en ambos casos, con una ligera ventaja para el modelo lineal en cuanto al valor del estimador R^2 pero con un buen comportamiento del modelo de árbol de decisión. Se discuten las conclusiones más significativas sobre los modelos y se proponen posibles extensiones y mejoras del trabajo.

2 Abstract

This Master thesis analyzes trips made by high-volume FHV services in New York City, with the objective of segmenting trip behavior and generating prediction models to estimate driver pay. The study is based on data provided by the New York Taxi and Limousine Commission (TLC). Given the large amount of available data, statistical inference models are used to address computational requirements. Data science techniques are applied, such as exploratory data analysis (EDA), unsupervised clustering algorithms, and both parametric (linear regression) and non-parametric (decision trees) predictive models. The models obtained are evaluated using standard validation metrics (R^2 , MAE, MAPE), which show satisfactory predictive capacity in both cases, with a slight advantage for the linear model in terms of the R^2 estimator, but with good performance from the decision tree model. The most significant conclusions regarding the models are discussed, and possible extensions and improvements to the work are proposed.

Keywords— FHV New York City, Data Analytics, Data Science, Clustering, K-Prototypes, Linear Regression, Decision Trees

Contents

1	Resumen	2
2	Abstract	2
3	Introducción	10
3.1	Contexto	10
3.2	Motivación del proyecto	11
3.3	Objetivos generales y objetivos específicos	11
3.4	Alcance del estudio	12
3.5	Estructura de la memoria	12
4	Revisión del estado del arte	13
4.1	Conceptos básicos	13
4.1.1	Vehículos de alquiler y movilidad urbana	13
4.1.2	Ciencia de datos aplicada a transporte	14
4.2	Estudios previos relevantes	15
4.3	Gap identificado y aportación del TFM	16
5	Datos y fuentes de información	18
5.1	Descripción de las fuentes de datos	18
5.2	Variables disponibles	19
5.3	Limitaciones y calidad de los datos	21
5.4	Proceso de adquisición de datos	22
6	Metodología empleada	23
6.1	Limpieza y preprocesamiento de los datos	23
6.2	Ingeniería de características	26
6.3	Análisis exploratorio de datos	27
6.4	Técnicas de visualización	28
6.5	Métodos de Machine Learning	28
6.5.1	Técnicas de clustering	29

6.5.2	Algoritmos para métodos de regresión	30
6.5.3	Modelos no paramétricos. Árboles de decisión	31
6.6	Estrategia de división de datos	32
6.7	Justificación de las herramientas y tecnologías elegidas	36
7	Análisis Exploratorio	37
7.1	Caracterización general de los viajes	37
7.2	Identificación de patrones relevantes	47
7.3	Análisis estructural (Grafo y sentido de los trayectos)	52
7.4	Segmentación exploratoria mediante clustering	56
8	Diseño del Modelo	68
8.1	Selección de variables y estructura del modelo de predicción	69
8.2	Evaluación de los supuestos del modelo	72
8.3	Entrenamiento y validación del modelo	73
8.4	Interpretación del modelo lineal	75
8.5	Generalización del modelo a otros meses	75
8.6	Árboles de decisión como modelo alternativo	76
8.6.1	Descripción y motivación	76
8.6.2	Ajuste del modelo y validación	76
8.6.3	Interpretación y comparación	77
9	Conclusiones y trabajo futuro	80
9.1	Hallazgos relevantes	80
9.2	Limitaciones del trabajo	81
9.3	Líneas de investigación futuras	81
10	Glosario	85
11	Anexos	86

List of Figures

1	Zonas TLC para servicios FHV en la ciudad de Nueva York (distrito de Manhattan resaltado) sobre fondo cartográfico de OpenStreetMap	19
2	Proporción de missing values para variable 'on_scene_datetime'	24
3	Gráficos con distribuciones incluyendo transformación de Box-Cox	24
4	Detección de outliers tras aplicar Elliptic Envelope	25
5	Elección del número de clústeres	30
6	Remuestreo bootstrap semanal sobre Pick-Ups (muestras de 10K)	34
7	Remuestreo bootstrap semanal sobre Pick-Ups (muestras de 20K)	34
8	Remuestreo bootstrap diario sobre Pick-Ups (muestras de 10K)	35
9	Remuestreo bootstrap diario sobre Pick-Ups (muestras de 20K)	35
10	Distribución de viajes por franja horaria desagregado por días de la semana	37
11	Distribución de viajes por franja horaria	38
12	Localizaciones de recogidas (Pick-Ups)	39
13	Pick-Ups ordenados	39
14	Top 30 Pick-Ups	40
15	Mapa Drop-Offs	41
16	Top 30 Drop-Offs	41
17	Trayectos en la misma zona vs diferente zona	42
18	Comparación de cuota de mercado entre compañías FHV	43
19	Número de Pick-Ups desagregado por franja horaria y compañía FHV	44
20	Servicio FHV dominante por localización de recogida (Pick-Up)	44
21	Comparativa por dominio territorial entre distintas compañías FHV	45
22	Pick-Ups por distritos o boroughs	46
23	Drop-Offs por distritos o boroughs	46
24	Variable Trip Miles	47
25	Variable Trip Time	48
26	Variables numéricas	49
27	Variable Driver Pay	50

28	Relación entre 'trip time' y 'driver pay'	51
29	Duración media del viaje por hora de recogida	51
30	Distancia media del viaje por hora de recogida	51
31	Mapa con tiempos medios por trayecto según punto recogida (Pick-Up)	52
32	Viajes FHV para Manhattan	53
33	Viajes FHV por distritos/boroughs	53
34	Viajes identificados por valores de 'driver pay' por encima de la mediana	54
35	Grafo con trayectos que incluyen 'airport fees'	55
36	Grafo con trayectos que incluyen pago de peajes (tolls)	55
37	Media clúster semanal	57
38	cluster 0 bootstrap semanal	57
39	cluster 1 bootstrap semanal	57
40	cluster 2 bootstrap semanal	58
41	Media clúster por horas	58
42	Desviación respecto de la media para origen	60
43	Desviación respecto de la media para destino	60
44	Orígenes de trayecto clúster 0	61
45	Variación en puntos porcentuales de orígenes de trayectos para el clúster 0	62
46	Variación en puntos porcentuales de destinos de trayectos para el clúster 0	62
47	Densidad de taxis para clúster 0	63
48	Número total de orígenes de trayecto para clúster 1	64
49	Variación en puntos porcentuales de orígenes de trayectos para el clúster 1	64
50	Variación en puntos porcentuales de destinos de trayectos para el clúster 1	64
51	Número total de orígenes de trayecto para clúster 2	66
52	Variación en puntos porcentuales de orígenes de trayectos para el clúster 2	67
53	Variación en puntos porcentuales de destinos de trayectos para el clúster 2	67
54	Distribución semanal de recogidas para la muestra aleatoria del random state 42	68
55	Distribución horaria de recogidas para la muestra aleatoria del random state 42	68
56	Matriz de correlación de Pearson	69

57	Dispersión de residuos por tipo de 'shared request flag'	71
58	Ejemplo de selección de variables por regularización L1	71
59	Dispersión de residuos por tipo de 'shared request flag' modelo de 3 variables	71
60	Conjuntos de entrenamiento y de test: valores reales frente a los predichos	74
61	Diagrama QQ de distribución de residuos	74
62	Distribución de residuos	75
63	Importancia de las variables para el árbol de decisión	77
64	Árbol de decisión: valores reales frente a predichos	78
65	Árbol de decisión	79
66	Viajes con mismo origen y destino por distritos o boroughs	86
67	Top 30 de viajes con mismo origen y destino	86
68	Mapa con trayectos en la misma zona	87
69	Mapas con orígenes de trayecto por compañía	87
70	Densidad de taxis por destino de trayecto clúster 0	88
71	Densidad de taxis por destino de trayecto clúster 1	91
72	Densidad de taxis por destino de trayecto clúster 2	92
73	Bootstrap de clústeres por horas	92
74	Número total de viajes por destino de trayecto clúster 0	94
75	Número total de viajes por destino de trayecto clúster 1	95
76	Densidad de taxis por origen de trayecto clúster 1	95
77	Número total de viajes por destino de trayecto clúster 2	96
78	Densidad de taxis por origen de trayecto clúster 1	97

List of Tables

1	Comparación entre <code>driver_pay</code> y <code>base_passenger_fare</code> en el modelo de datos de la TLC	21
2	Variables principales del conjunto de datos HVFHS de NYC TLC	21
3	Estadísticos descriptivos de las principales variables numéricas tras el preprocesamiento	23
4	Comparativa de resultados de clustering con diferentes tamaños de muestra	33
5	Localizaciones de origen más comunes para muestras de 1M - Mayo 2024	40
6	Vehicle License Data for Ride-sharing Companies	43
7	Estadísticas descriptivas de <code>trip_miles</code> por compañía	47
8	Estadísticas descriptivas de 'trip time' por compañía	48
9	Distribución de variables booleanas en datos de viajes	49
10	Estadísticas descriptivas de 'driver pay' por compañía	50
11	Centroides representativos de los tres clústeres generados con K-Prototypes	56
12	Distribución de valores binarios por clúster en variables categóricas	59
13	Distribución de viajes por borough de recogida en la muestra	61
14	Principales flujos de origen-destino dentro del Cluster 0	62
15	Principales flujos de origen-destino dentro del Cluster 1	65
16	Principales flujos de origen-destino dentro del Cluster 2	65
17	Distribución de viajes por borough de recogida en el Cluster 2	66
18	Top 5 zonas de destino más frecuentes dentro del Cluster 2	66
19	Estadísticos de diagnóstico del modelo	72
20	Desempeño del modelo en los conjuntos de entrenamiento y de test	73
21	Resultados del modelo de regresión con errores robustos (White-HC)	75
22	Evaluación del modelo de regresión lineal sobre diferentes muestras mensuales de 2024 con sus respectivas semillas	76
23	Rendimiento del árbol de decisión (con hiperparámetros óptimos)	77
24	Importancia de las variables en el modelo de árbol de decisión	78
25	Top 10 zonas de recogida más frecuentes en la muestra analizada	88
26	Top 10 zonas de destino más frecuentes en la muestra analizada	88
27	Top 10 zonas por densidad de recogidas (<code>cab density</code>) en Manhattan	89

28	Top 10 zonas de recogida más frecuentes (alternativo)	90
29	Top 10 zonas de destino más frecuentes en la muestra analizada (actualizado)	90
30	Top 10 zonas por densidad de recogidas (cab density) en Manhattan	91
31	Zonas con menor densidad de recogidas (cab density) en Manhattan	92
32	Desviación porcentual de distribución por borough respecto a la media global, por clúster	93
33	Desviación porcentual de distribución por borough de destino respecto a la media global, por clúster	93
34	Top 10 zonas por densidad de recogidas (cab density) en Manhattan	93
35	Distribución de viajes por borough de destino en la muestra	94
36	Distribución actualizada de viajes por borough de recogida en la muestra	94
37	Distribución actualizada de viajes por borough de destino en la muestra	95
38	Top 10 zonas por densidad de recogidas (cab density) en Manhattan	96
39	Top 10 zonas de recogida más frecuentes dentro del Cluster 2	96
40	Zonas con menor densidad de recogidas (cab density) en Manhattan	97
41	Distribución de viajes por borough de destino en el Cluster 2	97

3 Introducción

Durante la pasada década, el ecosistema de la movilidad urbana de las grandes urbes se ha visto transformado por el auge de los servicios de vehículos de transporte con conductor (FHV). En ciudades como Nueva York, este fenómeno ha tenido un impacto significativo y ha generado la necesidad de poner sobre la mesa el debate sobre la remuneración mínima para los conductores.

Este trabajo fin de máster tiene como objetivo el análisis de los viajes realizados mediante el uso de servicios de vehículos de alquiler con conductor (FHV) en la ciudad de Nueva York y proponer un modelo de predicción de la remuneración de los conductores, utilizando técnicas de ciencia de datos. En esta sección se presentará el contexto en el que se plantea el estudio, la motivación que está detrás del mismo, los objetivos que se buscan satisfacer, el alcance del proyecto y la estructura general de la memoria.

3.1 Contexto

En los últimos años, la movilidad urbana está experimentando una profunda transformación con la irrupción de nuevas formas de transporte impulsadas por plataformas digitales. Servicios de FHV como Uber o Lyft, han redefinido la manera en la que millones de personas se desplazan en las grandes ciudades.

La ciudad de Nueva York representa un caso paradigmático al respecto. Con una población estimada de más de ocho millones de habitantes (y un área metropolitana, con alrededor de veinte millones) y una alta densidad, Nueva York combina el ser tanto un polo financiero y económico global, como una gran atracción turística y de ocio. En ella confluyen diariamente múltiples modos de transporte, destacando además dos nodos intermodales como son los aeropuertos de JFK y LaGuardia los cuales concentran gran parte del tráfico de FHV.

El crecimiento sostenido en el número de licencias FHV ha generado la necesidad de implementar nuevas políticas públicas que garanticen la eficiencia del sistema, la equidad en la distribución de ingresos y la sostenibilidad del modelo. En este contexto, el análisis de datos se convierte en una herramienta esencial para comprender los patrones de uso, evaluar el rendimiento de los servicios y diseñar modelos predictivos que puedan informar sobre la toma de decisiones.

Este trabajo fin de de máster se enmarca sobre esa línea, aprovechando la disponibilidad de datos abiertos proporcionados por la NYC Taxi and Limousine Commission (TLC). En este contexto, destacan los siguientes aspectos clave que justifican el desarrollo del presente trabajo:

- La irrupción y consolidación de servicios FHV como parte esencial de la movilidad urbana actual.
- Las particularidades de la ciudad de Nueva York como entorno de estudio: alta densidad, nodos intermodales, y gran volumen de viajes.
- La reciente regulación en aspectos como la remuneración de los conductores y la sostenibilidad del sistema.
- La disponibilidad de datos abiertos y su potencial para aplicar técnicas de ciencia de datos orientadas al análisis, segmentación y predicción.

En definitiva, las investigaciones previas en los que se basa este trabajo sirven para mostrar como el análisis de datos aplicado al ámbito del transporte puede ofrecer información valiosa para mejorar la comprensión del fenómeno de la movilidad urbana y, en particular, sobre servicios de vehículo de alquiler con conductor.

3.2 Motivación del proyecto

El origen de este proyecto nace del interés por aplicar los conocimientos y técnicas de ciencia de datos a un ámbito de gran relevancia urbana y económica como es el de los servicios de transporte con conductor (FHV, por sus siglas en inglés) en una ciudad tan dinámica y compleja como Nueva York. La gran disponibilidad de datos detallados y abiertos proporcionados por la Comisión de Taxis y Limusinas (TLC) fue un estímulo clave para plantear un análisis exploratorio riguroso.

Además, el proyecto surge del deseo de vincular aspectos técnicos del análisis de datos con fenómenos del mundo real, en particular con la geografía urbana, el comportamiento espacial y la estimación de variables económicas como la remuneración del conductor (*driver pay*). A continuación, se recogen los principales ejes que fundamentan esta motivación:

- 1. Relevancia social y urbana:** El crecimiento de los servicios FHV ha transformado la movilidad en las grandes ciudades. Estudiar sus patrones de funcionamiento contribuye a entender su impacto en la congestión o el reparto modal, entre otros.
- 2. Interés en aplicar ciencia de datos a un problema real:** El análisis permite poner en práctica herramientas estadísticas, algoritmos de aprendizaje automático y técnicas visualización sobre un conjunto de datos relacionado con el sector de servicios FHV.
- 3. Valor para la toma de decisiones:** Un modelo que permita predecir el *driver pay* podría aportar valor a las distintas partes implicadas en el sector. Asimismo, la segmentación y análisis geográfico de los viajes permite detectar patrones útiles para diseñar políticas públicas o estrategias empresariales.

De forma complementaria, este trabajo responde también a una motivación personal y académica por profundizar en el análisis de datos aplicados al ámbito urbano y al sector de servicios FHV.

3.3 Objetivos generales y objetivos específicos

De acuerdo con lo expuesto en la sección "Motivación del proyecto", este trabajo pretende desarrollar un análisis basado en técnicas de ciencia de datos para comprender el comportamiento de los viajes en servicios de vehículos de transporte con conductor (FHV) en la ciudad de Nueva York, con especial atención a la segmentación de tipologías de viaje y la predicción del valor **driver pay**.

A continuación se enumeran los diversos objetivos específicos a conseguir a lo largo de este trabajo:

- 1** Realizar un análisis exploratorio de datos (EDA) que permita caracterizar los viajes en servicios FHV.
- 2** Estudiar las diferentes tipologías de viajes homogéneos mediante la implementación de técnicas de clustering (K-Prototypes) y facilitar el análisis de patrones de movilidad.
- 3** Desarrollar modelos predictivos robustos y generalizables del **driver pay** o remuneración del conductor, utilizando tanto modelos de regresión lineal como algoritmos no paramétricos (árboles de decisión), con el objetivo de estimar los ingresos esperados en función de variables observables en cada viaje.
- 4** Evaluar la importancia de variables geográficas tales como zonas de recogida y destino y su posible relación dentro del análisis de viajes.
- 5** Validar los análisis y modelos desarrollados mediante técnicas de inferencia estadística.

- 6 Ofrecer una interpretación orientada a negocio que permita detectar zonas de alta demanda, viajes económicamente relevantes o comportamientos recurrentes que pueden tener impacto.

3.4 Alcance del estudio

Este trabajo se limita geográficamente a la ciudad de Nueva York, considerando sus límites administrativos, y se centra cronológicamente en el mes de mayo de 2024, si bien se realizan validaciones puntuales sobre otros meses.

El análisis se focaliza en analizar los servicios de FHV de alta demanda (HVFHV). Es decir, en aquellas compañías de FHV que operan bajo una misma marca registrada y superan los 10.000 viajes diarios en la ciudad de Nueva York, según la clasificación de la NYC TLC.

A nivel metodológico, el estudio combina un análisis exploratorio (EDA), una segmentación en forma de clustering mediante el algoritmo de K-Prototypes y la construcción de modelos predictivos para estimar la variable *driver pay*, utilizando tanto métodos de regresión lineal como algoritmos de aprendizaje automático (*machine learning*), en particular, árboles de decisión.

El enfoque es principalmente académico y analítico. Se prioriza la interpretabilidad y la robustez frente a soluciones de complejidad excesiva o escasa explicabilidad, con el objetivo de obtener resultados comprensibles y aplicables en contextos reales.

Dadas las limitaciones técnicas derivadas del entorno de ejecución y recursos disponibles (hardware y memoria), se trabaja tomando muestras aleatorias de 20.000 observaciones, validadas mediante técnicas de remuestreo (bootstrap). Por otra parte, se sacrifica el uso de técnicas de Big Data en favor de un enfoque basado en conocimientos de inferencia estadística sobre muestras representativas.

Por último, aunque el modelo desarrollado se valida y generaliza sobre diferentes subconjuntos y momentos temporales, su alcance práctico busca simplemente ser analítico y exploratorio. Aún así, se abre la posibilidad a que el modelo pueda servir como base para estudios posteriores.

3.5 Estructura de la memoria

La presente memoria se estructura en siete secciones principales. Tras esta introducción, donde se expone el contexto, los objetivos, la motivación y el alcance del estudio, la sección 4 presenta una revisión del estado del arte, abordando investigaciones previas relevantes sobre movilidad urbana, servicios FHV y ciencia de datos aplicada al transporte.

En la sección 5 se describen las fuentes de información utilizadas, las características del conjunto de datos y las variables consideradas, así como las limitaciones asociadas a su tratamiento. A continuación, la sección 6 detalla la metodología empleada, incluyendo el preprocesamiento de los datos, la ingeniería de características, las técnicas de visualización, la estrategia de división del conjunto de datos, la validación mediante remuestreo y los algoritmos utilizados.

La sección 7 está dedicado al análisis exploratorio de datos, donde se identifican patrones relevantes, se realiza una segmentación de viajes mediante técnicas de clustering y se analizan aspectos espaciales y temporales del comportamiento de los servicios FHV. La sección 8 aborda el diseño e implementación de los modelos predictivos, tanto de regresión lineal como de machine learning, describiendo el proceso de selección de variables, entrenamiento, validación y evaluación e interpretación de resultados.

Finalmente, la sección 9 presenta las conclusiones del trabajo, destacando las aportaciones principales, las limitaciones del estudio y algunas posibles líneas de investigación futura.

4 Revisión del estado del arte

En los últimos años, el análisis de datos aplicados a la movilidad urbana ha cobrado especial relevancia con la irrupción de plataformas bajo demanda como Uber, Lyft o Via. En ciudades como Nueva York, donde la disponibilidad de datos abiertos ofrecidos por la Taxi and Limousine Commission (TLC) permite estudiar millones de trayectos cada mes, se han desarrollado diversos enfoques para modelizar patrones de viaje, pagos o eficiencia del sistema.

En este contexto, el presente trabajo quiere explorar la segmentación de la tipología de viajes y la posibilidad de predecir la remuneración estimada del conductor basándonos en estudios anteriores.

4.1 Conceptos básicos

4.1.1 Vehículos de alquiler y movilidad urbana

Conceptos básicos sobre vehículos de transporte con conductor (FHV)

Los vehículos de transporte con conductor (For-Hire Vehicle -FHV-, en inglés) son automóviles utilizados para transportar pasajeros a cambio de una tarifa, que deben ser solicitados con antelación por medio de una plataforma digital, a diferencia de los taxis tradicionales que pueden ser tomados directamente en la vía pública. Este grupo incluye servicios como Uber, Lyft, Via, entre otros.

En el caso de la ciudad de Nueva York, los FHV están regulados por la Taxi and Limousine Commission (TLC) y su proliferación desde la segunda década del siglo XXI ha transformado de manera sustancial el ecosistema de transporte urbano.

Movilidad urbana

La movilidad urbana se refiere al conjunto de desplazamientos de personas y mercancías dentro de un entorno urbano, englobando tanto medios motorizados como no motorizados.

En los últimos años, el concepto ha evolucionado hacia enfoques como la movilidad como servicio (MaaS), la movilidad sostenible y el transporte multimodal integrado, donde los FHV pueden jugar un papel clave.

Las ciudades, como Nueva York, enfrentan hoy en día desafíos cruciales: congestión creciente, inequidad en el acceso al transporte, impacto ambiental y necesidad de adaptar infraestructuras a nuevas formas de movilidad digitalizada. En este contexto, la ciencia de datos emerge como una herramienta poderosa para analizar patrones de viaje, evaluar el rendimiento del sistema y proponer soluciones basadas en evidencia.

La remuneración del conductor como variable de análisis

A diferencia de la tarifa que paga el usuario, la remuneración del conductor está determinada por una estructura compleja que combina una serie de elementos asociados con la carrera, el entorno, el desempeño y otras políticas estimadas. Esto convierte al ingreso del conductor en una variable sujeta tanto a decisiones operativas como a condiciones externas.

4.1.2 Ciencia de datos aplicada a transporte

En los últimos años, el auge de los servicios de transporte bajo demanda ha impulsado el uso de herramientas avanzadas en ciencia de datos para analizar, planificar y optimizar los sistemas de movilidad urbana. En este contexto, la recopilación y tratamiento de datos a gran escala se ha convertido en elemento clave para comprender los patrones de uso, predecir la demanda y evaluar el impacto de los servicios FHV (For-Hire Vehicles) en las ciudades.

Estudios recientes han tratado de estimar el impacto de los patrones de viaje sobre los ingresos de los conductores, encontrando que la ubicación y el momento del día son determinantes clave. Asimismo, se ha observado que las decisiones de posicionamiento geográfico y la anticipación de la demanda son estrategias que influyen significativamente en los ingresos obtenidos por hora.

La encuesta sobre tecnología en la movilidad urbana publicada por Verra Mobility y realizada por Wakefield Research (Verra Mobility Corporation [2024]) a una muestra de 100 directores de tecnología y subdirectores de tecnología de ciudades americanas revela la necesidad de integrar los servicios FHV en la planificación urbana. Esta integración debe ir acompañada del uso integrado de inteligencia artificial y análisis de datos como herramientas para mejorar las estrategias de movilidad de las ciudades, la eficiencia y la seguridad de los servicios FHV así como optimizar la asignación de recursos y planificación de rutas.

Vizuite-Luciano et al. [2023] refuerzan esta visión con un análisis bibliométrico exhaustivo sobre 7.000 artículos de la investigación académica sobre movilidad urbana y taxis publicados entre 1967 y 2021, extraídos de la base de datos Web of Science Core Collection. Su estudio identifica a los autores más influyentes y sus redes de coautoría y la repetición de palabras clave para identificar tendencias temáticas. En este último caso, se ha detectado un aumento en el uso de términos clave como "ride-sourcing", "ride-pooling" o "movilidad compartida" y un crecimiento sostenido global en relación a publicaciones relacionadas con la movilidad urbana y los taxis, especialmente en la última década.

Además, la National Board of Economic Research (NBER) (National Bureau of Economic Research [2021]) realizó una recopilación exhaustiva de conjuntos de datos relacionados con servicios FHV en las principales áreas metropolitanas de EE.UU., incluyendo los datos provistos por la NYC TLC. Esta recopilación representa una base empírica indispensable para analizar la evolución y el impacto de servicios como Uber, Lyft y taxis tradicionales en la movilidad urbana. En particular, Qian et al. [2020] han utilizado trayectorias reales a gran escala para estudiar cómo los FHV afectan a la congestión en ciudades como Nueva York.

Del mismo modo, estudios como el de Conway et al. [2018a] han empleado datos geográficos y demográficos para construir modelos predictivos de demanda y de ingresos de conductores, destacando la importancia del análisis espacial en este tipo de investigaciones. Este enfoque permite capturar las variaciones locales en el comportamiento de la movilidad.

En resumen, la ciencia de datos se ha consolidado como un componente esencial en el estudio de transporte urbano, no sólo como herramienta descriptiva, sino también como base para el diseño de modelos predictivos y de apoyo a la toma de decisiones. La presente investigación se inscribe en esta línea, aplicando técnicas de análisis de datos masivos al estudio del comportamiento y compensación del sistema de remuneración de conductores en el ecosistema de servicios FHV de la ciudad de Nueva York.

4.2 Estudios previos relevantes

Diversos estudios e informes han abordado la evolución de la movilidad urbana en EE.UU., prestando especial atención al papel de los servicios FHV (For-Hire Vehicles), como Uber o Lyft. En su informe especial, el Transportation Research Board [2015] analiza el crecimiento y la diversificación de los servicios de movilidad habilitados por la tecnología, explorando sus implicaciones para los consumidores, los servicios de transporte existentes y las políticas públicas.

Un punto de partida clásico para comprender la evolución de la congestión urbana es el informe del Instituto de Transporte de Texas (Schrank and Lomax [2002]) que abarca el período 1982-2000 en 75 áreas urbanas de EE.UU., incluida Nueva York. Este informe muestra un crecimiento sostenido de la congestión en hora punta, junto con un aumento del impacto económico asociado, el porcentaje de vías principales congestionadas y del tiempo promedio de retraso por viajero.

La integración de los FHV con otros modos de transporte también ha sido analizada. Por ejemplo King et al. [2020], en un estudio de la Universidad Estatal de Arizona, halló que un 75% de los recorridos con FHV se combinan con otros modos de transporte y un 27% lo combinan con transporte público. En particular, en California, aproximadamente el 11% de los recorridos en FHV se utilizan como solución de última milla para acceder al transporte público. Estos resultados pueden ser extrapolables a los trayectos con destino a nodos intermodales de transporte como los aeropuertos, eje clave en este trabajo.

En el ámbito internacional, el informe de la OCDE (Crozet [2020]) subraya cómo servicios como Uber o Lyft han transformado el panorama del transporte urbano, planteando nuevos desafíos en términos de regulación y uso del espacio vial. Paralelamente, Moss and O'Neill [2012] desde el NYU Rudin Center –en colaboración con BMW i– ofrecen una visión prospectiva más amplia sobre los desafíos y oportunidades de la movilidad urbana del siglo XXI teniendo en cuenta factores como el crecimiento urbano global, el envejecimiento de la población y el aumento de hogares unipersonales, así como la necesidad de rediseñar el espacio dedicado al estacionamiento.

Bajando al contexto neoyorquino, el Departamento de Transporte de la ciudad de Nueva York (NYC DOT), Schrank et al. [2019], constata un aumento significativo (casi un 90%) de los viajes en FHV durante la última década, correlacionado con un menor uso del transporte público (metro y autobuses) lo que ha provocado la congestión en las calles de la ciudad. Más de la mitad del tráfico vehicular se atribuyen a taxis y FHVs frente al 33% que representan automóviles privados. En esta línea, Qian et al. [2020] también destaca el aumento de emisiones contaminantes asociado al uso intensivo de servicios FHV en Nueva York.

Desde una perspectiva sobre la evolución del uso de vehículos en EE.UU, el trabajo de Conway et al. [2018b] analiza la transición hacia el auge del servicio de viaje bajo demanda (*ridehailing*) entre 1995 y 2017. Se detecta un crecimiento considerable del uso de servicios FHV, especialmente entre el periodo 2009-2017, con un perfil de usuario centrado en adultos jóvenes, con ingresos altos y residentes en áreas metropolitanas densas como el principal grupo de consumidores de este tipo de servicios. Por su parte, King et al. [2020] hallaron que el uso de estos servicios aumenta por las últimas horas de la tarde y la noche, coincidiendo con una menor disponibilidad del servicio de transporte público. Complementando este análisis temporal, Natashia and Velu [2020] estudian la variación temporal sobre patrones de uso de taxis según la franja horaria y el día de la semana.

Con respecto a la perspectiva institucional, la Administración Federal de Carreteras (FHWA) publicó su informe sobre movilidad compartida (Shaheen et al. [2016]), donde se aborda el rol de las agencias públicas a la hora de regular estos servicios de servicio de movilidad intermediada por plataforma (*ridesourcing*), sin obstaculizar la integración tecnológica y la recopilación de datos para una planificación efectiva.

A nivel local, el informe sobre mejora en la eficiencia y gestión del crecimiento en el sector FHV de Nueva York publicado por la TLC NYC en Junio de 2019 (New York City Taxi and Limousine Commission and New York City Department of Transportation [2019]) propone políticas para mejorar la eficiencia del sector mediante la introducción de políticas regulatorias más estrictas a la hora de licitar nuevas licencias FHV, así como el establecimiento de una tarifa mínima para servicios de ridehailing. El informe además advierte que si los cambios regulatorios no se implementan correctamente, estos podrían afectar a las ganancias netas de los conductores. Paralelamente, el estudio de Konishi et al. [2023] examinaron 50 millones de trayectos de servicios FHV entre 2019 y 2022 mostrando la dispar evolución entre los ingresos de los conductores y las comisiones que retienen las plataformas de FHV. Se destaca un aumento de la tarifa media por viaje del 50% entre febrero de 2019 (\$12,22) y abril de 2022 (\$18,39), mientras que la retribución media al conductor sólo creció un 31% (del \$10,99 al \$14,41 en ese mismo periodo). Por su parte, Natashia and Velu [2020] identificaron zonas geográficas donde se concentra la demanda de servicios, reflejando una alta actividad económica y social de la ciudad.

En términos de tendencias más recientes, el informe sobre movilidad urbana de 2023 publicado por el Texas A&M Transportation Institute (Schrack et al. [2024]) indica que en 2022 se recuperaron los niveles pre-pandemia en relación a la congestión de tráfico. Pese a ello se detectaron ciertas variabilidades en función de la región influenciadas por factores como el retorno al trabajo presencial y las políticas locales de transporte.

Fuera del caso específico de Nueva York, el Departamento de Transporte de Los Ángeles (LADOT) -según el estudio publicado por Sam Schwartz Engineering [2019]- reporta un declive del uso del taxi, la regulación desigual entre distintos servicios y un sistema de franquicias obsoleto que debe ir dando paso a sistemas de permisos (o licencias). Además, se destaca la preferencia del consumidor por servicios FHV debido a su menor tiempo de espera y mayor facilidad de uso.

Finalmente, el estudio sobre nuevas tecnologías y movilidad sostenible de la Fundación Heinrich Böll (Borade et al. [2020]) pone de relieve el crecimiento acelerado del uso de servicios FHV en ciudades americanas, transformando la movilidad urbana de éstas y cómo éstos han podido influir en el aumento de la congestión vehicular, especialmente en áreas urbanas densas mientras disminuye el uso del transporte público como medio de desplazamiento.

4.3 Gap identificado y aportación del TFM

La literatura revisada ofrece un marco teórico y empírico sólido sobre la evolución de la movilidad urbana, los impactos del crecimiento de la demanda de transporte y la aparición de nuevos servicios de movilidad. El estudio sobre movilidad urbana del Instituto de Transporte de Texas (Schrack and Lomax [2002]) proporciona una base robusta para comprender cómo el crecimiento de la demanda afecta a los tiempos de viaje, la eficiencia del sistema y los costes individuales. Los datos permiten contextualizar la evolución del transporte en Nueva York y otras ciudades durante un periodo crítico, antes del auge de servicios como Uber o Lyft. Por su parte, el artículo Transportation Research Board [2015] tiene en cuenta consideraciones de equidad y acceso, e insta a una amplia recolección y análisis de datos.

Konishi et al. [2023] abordan de manera específica el efecto de los FHV sobre la distribución de ingresos y las posibles consecuencias de políticas regulatorias al respecto. No obstante, este estudio no profundiza en los patrones espaciales y temporales del uso de estos servicios. Por su parte, National Bureau of Economic Research [2021] sí que realiza un análisis de patrones de movilidad. Por otro lado, el trabajo de Vizuet-Luciano et al. [2023] aporta un marco teórico sólido que sirve como base para contextualizar este trabajo en tendencias actuales en movilidad urbana, y puede servir para identificar vacíos en la literatura y seleccionar fuentes relevantes.

El informe de Schrack et al. [2024] permite observar las tendencias generales sobre el impacto de los

servicios FHV en áreas urbanas específicas y evaluar como éstos servicios se integran en el panorama general de la movilidad urbana, especialmente en su relación con otros modos de transporte. Del mismo modo, el estudio de Sam Schwartz Engineering [2019], centrado en el caso de LADOT, plantea soluciones transferibles como posible modelo para otras ciudades que enfrentan desafíos similares. Sin embargo, hay que tener en cuenta que Los Ángeles se rige por la gran extensión de territorio y mayor uso del vehículo particular obligado frente a una ciudad más densa como es Nueva York. Esto plantea interrogantes sobre cómo varía el impacto de los FHVs en la congestión y movilidad urbana.

La Federal Highway Administration [2020] da una contextualización geográfica de los servicios FHV y observa cómo se integran en tendencias más amplias de movilidad compartida y su impacto en la planificación urbana. Además introduce una visión sobre cómo las regulaciones y el desarrollo de políticas públicas regulan y optimizan el uso de FHV en entornos urbanos. Finalmente, Natashaia and Velu [2020] muestran una metodología rigurosa a la hora de tratar y analizar datos sobre servicios de taxi tradicional en Nueva York (yellow taxis) y green taxis para detectar patrones de movilidad urbana. En su caso, utiliza registros de viajes de taxis tradicionales (yellow taxis) y su variante green taxis (New York Dearest [2023]). Estas metodologías son extrapolables al análisis de servicios FHV y permiten hacer comparaciones entre patrones de movilidad.

En este contexto, el presente trabajo proporciona una caracterización y modelización detallada de los viajes FHV en Nueva York, combinando técnicas de análisis exploratorio, clustering y regresión predictiva. Se aplica una perspectiva metodológica reproducible que permite no solo entender patrones temporales y espaciales, sino también estimar con precisión el 'driver pay', variable clave para comprender el funcionamiento económico del sistema.

5 Datos y fuentes de información

5.1 Descripción de las fuentes de datos

Los datos utilizados en este trabajo han sido extraídos del portal de datos abiertos de la NYC Taxi & Limousine Commission (TLC) (New York City Taxi and Limousine Commission [2025a]), organismo responsable de regular los servicios de transporte en la ciudad de Nueva York. Esta entidad pública mensualmente registros detallados de los trayectos realizados por los distintos tipos de vehículos autorizados: taxis amarillos (yellow taxis), taxis verdes (green taxis) y servicios de vehículos de alta demanda (High Volume For-Hire Vehicle Services, HVFHVS), entre otros.

En este estudio se ha trabajado específicamente con datos correspondientes a los HVFHVS, un tipo de servicio que agrupa a las plataformas digitales de transporte de alta demanda como Uber, Lyft y similares. A diferencia de los taxis tradicionales, estos servicios operan principalmente mediante reservas por aplicación móvil y no pueden ser tomados directamente en la calle. Desde febrero de 2019, las compañías que realizan más de 10.000 trayectos al día están obligadas por la TLC a reportar sus viajes bajo la categoría HVFHVS, con un formato específico (New York City Taxi and Limousine Commission [2018a], New York City Taxi and Limousine Commission [2021]).


El conjunto de datos seleccionado para el análisis corresponde al mes de mayo de 2024, con un volumen superior a los 20 millones de registros. Cada entrada en el dataset representa un viaje individual e incluye información como: hora de recogida y llegada, identificadores de ubicación, distancia recorrida, duración, recargos aplicados o cantidad pagada al conductor ('driver pay'), entre otras variables.

Para interpretar correctamente los campos del dataset, se ha utilizado como referencia el diccionario de datos oficial proporcionado por la NYC TLC, disponible en: https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_hvfhs.pdf. (New York City Taxi and Limousine Commission [2025b]).

Para facilitar la comprensión espacial de los datos analizados, se incluye a continuación un mapa (Ver figura 1) que representa las zonas geográficas definidas por la TLC para servicios FHV en la ciudad de Nueva York. Estas zonas, identificadas por códigos numéricos (PULocationID, DOLocationID), se utilizan en los registros de viajes para indicar los puntos de recogida y destino.

Figura 1: Zonas TLC para servicios FHV en la ciudad de Nueva York (distrito de Manhattan resaltado) sobre fondo cartográfico de OpenStreetMap

Zonas FHV NYC con fondo OSM y Manhattan resaltado



5.2 Variables disponibles

El conjunto de datos proporcionado por la NYC TLC para los servicios HVFHVS incluye una amplia variedad de variables numéricas, categóricas y temporales. Estas variables describen cada viaje individual registrado en el sistema, incluyendo su ubicación, duración, costes y características operativas.

Las principales variables disponibles en el dataset son:

- **trip_time / trip_miles:** duración del viaje en segundos y distancia recorrida en millas.
- **driver_pay:** importe mínimo garantizado que el conductor debe recibir por el trayecto, según las normas de la TLC (\$17.22 USD/hora, New York City Taxi and Limousine Commission)

[2018b]).

- **PULocationID / DOLocationID:** identificadores numéricos de las zonas de recogida y destino.
- **pickup_datetime / dropoff_datetime:** fechas y horas de inicio y fin de viaje.
- **base_passenger_fare:** tarifa base que paga el pasajero al aceptar el viaje en la aplicación.
- **Recargos e impuestos:** tolls, sales_tax, airport_fee, bcf (black_car_fund), congestion_surcharge.
- **Variables booleanas:** por ejemplo, si se solicitó un vehículo accesible (wav_request_flag), si el trayecto ocurrió en un vehículo accesible para movilidad reducida (wav_match_flag), si hubo coincidencia de viaje compartido (shared_match_flag) o si el pasajero aceptó compartir un viaje (shared_request_flag).
- **Categorías relacionadas con licencias:** identificador de empresa HVFHV (hvfhs_license_num), número de licencia base expedido por la TLC (dispatching_base_num), número base que recibió la petición original de viaje (originating_base_num)

Estructura general

Los datos están organizados en formato tabular, originalmente en ficheros .parquet, con columnas que combinan tipos numéricos (ej. 'trip miles'), categóricos (PULocationID) o temporales ('pickup_datetime'). Tal y como se verá en la sección 6.1, la conversión a dataframe de pandas permitió su tratamiento y transformación posterior.

Sobre la variable 'driver pay'

La variable 'driver pay' representa la cantidad mínima necesaria que el conductor debe recibir por parte de la empresa de transporte (Uber, Lyft, etc.), en cumplimiento con la normativa de la NYC TLC. Esta cantidad está basada en una combinación entre distancia, duración estimada y otros aspectos sobre la actividad. Ésta no coincide necesariamente con la tarifa pagada por el pasajero. Es considerada como una variable crítica a lo largo de este estudio, ya que se utilizará como objetivo a predecir en los modelos de aprendizaje supervisado.

Diferencias entre 'driver pay' y 'base passenger fare'

Una diferencia fundamental en el conjunto de datos es la que existe entre las variables 'driver pay' y 'base passenger fare'. Aunque ambas están relacionadas con el coste del viaje, se refieren a conceptos distintos y cumplen funciones diferentes dentro del modelo de negocio de las plataformas de transporte.

En el contexto de la NYC Taxi and Limousine Commission (TLC), 'driver pay' representa la remuneración que debe recibir un conductor por cada viaje realizado bajo plataformas como Uber o Lyft (New York City Taxi and Limousine Commission [2018b]).

Por otro lado, la variable 'base passenger fare' refleja la tarifa estimada que paga el pasajero al confirmar un viaje en la app y se basa en una predicción previa de duración y distancia (Uber Technologies Inc. [2021]). Ésta última suele ser superior a la primera.

Concepto	Driver Pay	Base Passenger Fare
¿Quién lo recibe/paga?	Lo recibe el conductor	Lo paga el pasajero
¿Quién lo calcula?	La TLC establece un mínimo obligatorio	La empresa de HV-FHVS (Uber, Lyft, etc.)
¿Qué incluye?	Tiempo + distancia mínima garantizada + actividad	Cargos base + tiempo + distancia + posibles recargos
¿Puede variar?	No puede ser menor al mínimo TLC	Sí, varía según demanda, promociones, tráfico, etc.
Relación entre ellos	Puede ser menor, igual o mayor que la base fare	Generalmente mayor que el driver pay

Table 1: Comparación entre `driver_pay` y `base_passenger_fare` en el modelo de datos de la TLC

Este trabajo se centra en predecir 'driver pay' a partir de variables observables del trayecto (ver tabla 2), imitando así, en parte, la lógica de estimación anticipada que utilizan las plataformas para mostrar el precio al pasajero.

Variable	Descripción	Tipo de dato
<code>pickup_datetime</code>	Fecha y hora de inicio del viaje	Temporal
<code>dropoff_datetime</code>	Fecha y hora de fin del viaje	Temporal
<code>PULocationID</code>	Código de zona de recogida (TLC Zone)	Catórica (int)
<code>DOLocationID</code>	Código de zona de destino (TLC Zone)	Catórica (int)
<code>trip_time</code>	Duración del viaje en segundos	Númerica (int)
<code>trip_miles</code>	Distancia recorrida en millas	Númerica (float)
<code>driver_pay</code>	Pago mínimo garantizado al conductor	Númerica (float)
<code>base_passenger_fare</code>	Tarifa base que paga el pasajero	Númerica (float)
<code>tolls</code>	Total de peajes pagados durante el viaje	Númerica (float)
<code>sales_tax</code>	Impuesto de venta aplicado al viaje	Númerica (float)
<code>airport_fee</code>	Recargo por recogida/entrega en aeropuerto	Númerica (float)
<code>congestion_surcharge</code>	Recargo por congestión (ej. Manhattan)	Númerica (float)
<code>black_car_fund</code>	Contribución obligatoria al fondo estatal	Númerica (float)
<code>wav_request_flag</code>	Solicitud de vehículo accesible	Catórica (bool)
<code>wav_match_flag</code>	Verificación de viaje en vehículo accesible	Catórica (bool)
<code>shared_match_flag</code>	Coincidencia con otro durante el viaje compartido	Catórica (bool)
<code>shared_request_flag</code>	Aceptación de compartir con otro el viaje	Catórica (bool)

Table 2: Variables principales del conjunto de datos HVFHS de NYC TLC

Para garantizar una comprensión precisa de cada variable, se ha utilizado como referencia el diccionario de datos oficial de la NYC TLC New York City Taxi and Limousine Commission [2025b].

5.3 Limitaciones y calidad de los datos

El análisis de datos del servicio de vehículos de alquiler de alta demanda (HV-FHVS) presenta ciertas limitaciones asociadas tanto al volumen como a la estructura y disponibilidad de la información.

Volumen de datos y limitaciones técnicas

El conjunto de datos original correspondiente al mes de mayo de 2024 supera los 20 millones de registros, lo que representa un volumen considerable para su procesamiento en entornos con recursos limitados.

Estructura y formato de los datos

Los datos son de naturaleza estructurada, con variables de tipo numérico, categórico y temporal. Durante el preprocesamiento, algunas variables debieron ser transformadas de su tipo original (como se verá en la sección 6.1). Estas operaciones fueron necesarias para asegurar la correcta interpretación y análisis posterior.

Ausencia de datos (missing values)

Se identificó la presencia de valores ausentes (missing values) en determinadas columnas, pese a que en la mayoría de los casos fue explicable por la propia naturaleza del servicio. Por ejemplo, la variable "on_scene_datetime" que indica cuándo llegó el conductor al punto de recogida, este campo solo aparece con valor en los casos con viaje realizado con vehículos accesibles (WAV). En la sección 6.1 se entrará en mayor detalle sobre como se procedió a tratar estas situaciones.

Accesibilidad y licencia

Los datos utilizados en este trabajo son públicos, abiertos y de libre acceso, proporcionados por la NYC Taxi and Limousine Commission (TLC). Están disponibles de forma mensual y segmentados por tipo de servicio a través del portal oficial:

<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

5.4 Proceso de adquisición de datos

Los datos utilizados en este estudio fueron descargados directamente desde la página oficial de la NYC Taxi & Limousine Commission (TLC), New York City Taxi and Limousine Commission [2025a], a través del portal de datos abiertos disponible en:

<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

Concretamente, se accedió al archivo correspondiente al servicio HVFHVS (High Volume For-Hire Vehicle Services) del mes de mayo de 2024, el cual fue proporcionado en formato .parquet. Este formato está diseñado para almacenar grandes volúmenes de datos de manera eficiente, tanto en espacio como en velocidad de lectura.

Para evitar problemas de rendimiento derivados de la carga en memoria de un fichero de más de 20 millones de registros, se adoptó una estrategia eficiente basada en la lectura de metadatos mediante la librería pyarrow. Esta técnica permitió determinar el número total de registros y columnas disponibles, sin necesidad de cargar el contenido completo del fichero.

A partir de esa información estructural, se generó una muestra aleatoria de un millón de registros directamente desde el .parquet, que se exportó a un fichero .csv. Este enfoque permitió minimizar el uso de memoria y facilitar el procesamiento posterior en entornos locales o en otro tipo de entornos como Google Colab o Kaggle preparados para procesar notebooks de python.

Esta fase de adquisición y muestreo fue crítica para hacer viable el análisis desde el punto de vista computacional, sin comprometer la calidad ni la representatividad de los datos. La selección de campos y la interpretación de los mismos se apoyó en el diccionario de datos oficial de la NYC TLC.

6 Metodología empleada

Esta sección describe el conjunto de técnicas, herramientas y enfoques utilizados para el tratamiento, análisis y modelado de los datos de viajes de servicios de vehículos de alquiler en la ciudad de Nueva York. Se detallan las etapas clave del proceso, desde la limpieza y preprocesamiento del conjunto de datos, pasando por la ingeniería de características, el análisis exploratorio y la aplicación de modelos estadísticos y de aprendizaje automático.

6.1 Limpieza y preprocesamiento de los datos

La etapa de limpieza y preprocesamiento de datos resulta fundamental para garantizar la calidad y fiabilidad tanto del análisis posterior como de la generación de un modelo riguroso. En este trabajo, se partió originalmente de un conjunto de datos en formato `.parquet` proporcionado por la NYC TLC. Dadas las restricciones y dificultades de procesar volúmenes de datos tan elevados (aproximadamente 20 millones de observaciones por mes), se seleccionó una muestra aleatoria de 1 millón de registros para aligerar su manejo y evitar posibles limitaciones ya fuera en disco o en memoria.

Conversión de tipos y tratamiento de fechas

Las variables con sufijo `"_datetime"` (como `"pickup_datetime"` o `"request_datetime"`) se convirtieron al tipo `"datetime"` de pandas, siguiendo la norma ISO-8601 (iso [2019]), para permitir su correcta manipulación temporal. Se prestó especial atención a la variable `"on_scene_datetime"`, que contiene una gran cantidad de valores ausentes (NA). De acuerdo con la definición del diccionario de datos (?), esta variable solo se aplica a aquellos vehículos accesibles para personas con movilidad reducida. Por lo tanto, es esperable que no haya datos en la gran mayoría de viajes. En dichos casos, se imputó su valor con el correspondiente en `'pickup_datetime'` para mantener la coherencia temporal.

Validación de variables y limpieza de valores anómalos

Para el caso de determinadas variables numéricas críticas tales como: `'trip_miles'`, `'trip_time'`, `'driver_pay'` o `'transfer_time'` se forzó a que estas tuvieran valores estrictamente positivos. Como resultado de esta depuración inicial, se eliminaron un 0,94% de los registros originales.


Posteriormente se realizó un análisis estadístico descriptivo de las variables numéricas tratadas tal y como se observa en la tabla 3. Más allá de comprobar que ya no había valores que no fueran estrictamente positivos, se observó una alta dispersión en los valores, con colas largas y diferencias significativas entre los cuartiles superiores ($p=75$) y los máximos. Esto indicaba la presencia de valores atípicos (outliers).

Variable	count	mean	std	min	25%	50%	75%	max
trip_time	990.650	1256,50	925,62	1,00	619,00	1007,00	1612,00	20661,00
trip_miles	990.650	5,11	5,89	0,007	1,59	3,04	6,39	326,35
driver_pay	990.650	20,67	17,62	0,13	9,17	15,37	25,99	851,46

Table 3: Estadísticos descriptivos de las principales variables numéricas tras el preprocesamiento

Por otra parte, se estudió la existencia de valores ausentes (missing values) en cada variable. Dado que la muestra obtenida correspondía a un millón de observaciones, era necesario implementar una función capaz de procesar la posible variación de NAs para cada muestra y cada mes. En la figura 2 se muestra un ejemplo de gráfico de sectores con el porcentaje de NAs para una variable concreta.

Figura 2: Proporción de missing values para variable 'on_scene_datetime'
Proportion of Missing and Non-Missing Values for on_scene_datetime




Para cada muestra de un millón de observaciones se observó que las proporciones de NAs en dichas variables se mantenía prácticamente constante. Esto sirvió en parte para validar la primera selección de muestreo aleatorio y poder aligerar el procesamiento y análisis.

En cuanto a cómo se procesaron estos NAs, para el caso de la variable 'on scene datetime' (figura 2) se procedió tal y como se comentó en el apartado ('Conversión de tipos y tratamiento de fechas'). Por el contrario, la variable 'originating base num' fue descartada para los propósitos de este estudio. Lo cual no quiere decir que no pueda tener interés si la finalidad fuese otra.

Tratamiento de outliers


Para el tratamiento de outliers, se descartó el uso de métodos univariantes clásicos tales como la regla de las tres sigmas o el rango intercuartilico (IQR $\pm$ D) debido a la naturaleza asimétrica y de colas pesadas de la distribución de los datos. En su lugar, se optó por un enfoque multivariante usando el método "EllipticEnvelope" de la biblioteca scikit-learn (scikit-learn developers [2025]), no sin antes transformar la distribución de los datos a gaussianas. Para cumplir los supuestos del modelo, las variables seleccionadas ('trip miles', 'trip time') fueron previamente transformadas mediante la técnica de Box-Cox para asegurar la distribución gaussiana. Tras la aplicación de la transformación de Box-Cox se obtuvieron parámetros lambda con valores cercanos a cero.

Figura 3: Gráficos con distribuciones incluyendo transformación de Box-Cox



El modelo de detección de outliers se configuró con los siguientes hiperparámetros: `contamination = 7e-4`, `support_fraction = 0.98` y con la distancia Mahalanobis. Usando esta configuración sobre el método "EllipticEnvelope" se identificaron y eliminaron el 0,07% de los datos considerados como atípicos y sin comprometer la representatividad del conjunto.

Figura 4: Detección de outliers tras aplicar Elliptic Envelope



El hiperparámetro "contamination" indica la proporción de outliers mínima que va a detectar el algoritmo. Por su parte, "support_fraction" indica la cantidad de datos mínimos que se aseguran que no serán considerados como outliers. Se escogen estos datos para minimizar el número de outliers detectados. Por último, se toma la distancia Mahalanobis como medida de disimilitud por defecto. Ésta se caracteriza por tomar la covarianza entre variables aleatorias:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\mathbf{x} - \boldsymbol{\mu})}$$

Los puntos mostrados en color rojo oscuro en la figura 4 se corresponden con aquellos que están "más lejos" de la media vectorial, es decir, aquellos cuya distancia de Mahalanobis es mayor.

Resultados del preprocesamiento

Tras aplicar las etapas de limpieza y tratamiento de outliers, se pudo conservar cerca del 99% de los datos originales. En este punto, el conjunto de datos depurado consta de 28 variables, listas para las posteriores fases de ingeniería de características y selección de variables.

6.2 Ingeniería de características

Una vez finalizado el proceso de limpieza y tratamiento de outliers, se procedió a la generación de nuevas variables y a la transformación de las existentes con el objetivo de mejorar la capacidad explicativa del conjunto de datos y, a su vez, facilitar la construcción de modelos predictivos más precisos.

Variables temporales derivadas

A partir de las variables tipo "datetime", se extrajeron componentes temporales relevantes:

- Hora del día (*_datetime_hour): permite capturar patrones de comportamiento en función del momento del día.
- Día de la semana (*_datetime_dayofweek): útil para detectar diferencias entre días laborables y fines de semana.

Estas transformaciones se realizaron para mejorar la operabilidad y el análisis. Las variables datetime originales no se utilizarán, en ningún caso, directamente en los modelos.

Cálculo de tiempos intermedios

Por otra parte, también se crearon dos variables que capturaron aspectos temporales clave del proceso de recogida:

- Transfer time (transfer_time): diferencia entre 'pickup_datetime' y 'request_datetime', que indica el tiempo que un conductor tarda en llegar al punto de encuentro tras recibir la notificación del viaje.

```
trips['transfer_time'] = (trips['pickup_datetime'] - trips['request_datetime']).dt.total_seconds()
```

- Buffer time (buffer_time): diferencia entre 'pickup_datetime' y 'on_scene_datetime', que refleja el tiempo que tarda en iniciarse el viaje una vez ha llegado el conductor al punto de encuentro y se ha acomodado al pasajero con movilidad reducida.

```
trips['buffer_time'] = (trips['pickup_datetime'] - trips['on_scene_datetime']).dt.total_seconds()
```

Variables espaciales agregadas

Para enriquecer el análisis geográfico, se agruparon los identificadores de localización (PULocationID, DOLocationID) por distritos administrativos de Nueva York (boroughs): Manhattan, Brooklyn, Bronx, Queens, Staten Island y el aeropuerto de Newark -información provista por los ficheros shapefile Taxi Zone en New York City Taxi and Limousine Commission [2025a]-. En los casos en los que no fue posible asignar un distrito debido a la ausencia de un polígono correspondiente en los mapas GIS, se imputó el valor 'Out_of_City', considerando posibles trayectos interurbanos:

```
trips['PUborough'].fillna('Out_of_City', inplace=True)  
trips['DOborough'].fillna('Out_of_City', inplace=True)
```

6.3 Análisis exploratorio de datos

En esta subsección se detallan las técnicas y herramientas utilizadas para explorar y comprender los datos antes de su modelado. El objetivo consistió en identificar patrones generales, detectar valores atípicos, evaluar la calidad de los datos y orientar las decisiones de limpieza y transformación.

En el caso de la lectura y transformación de datos, los datos originales se encontraban en formato .parquet y fueron convertidos a .csv para facilitar su manipulación con la librería pandas de python.

Para facilitar el manejo de esa gran cantidad de datos se ejecutaron las instrucciones que se describen a continuación, con el fin de extraer 1.000.000 de registros sin necesidad volcar a memoria todo el fichero .parquet:

```
# Paso 1: Usamos dataset de PyArrow para manejar grandes volúmenes
dataset = ds.dataset(parquet_file, format="parquet")
table_metadata = pq.read_metadata(parquet_file)

# Paso 2: Obtenemos el número total de filas
# (Solo es confiable si los archivos Parquet contienen metadatos actualizados)
table_metadata = pq.read_metadata(parquet_file)
total_rows = table_metadata.num_rows

# Paso 3: Definimos el tamaño de la muestra
sample_size = 1_000_000

# Paso 4: Seleccionamos índices aleatorios
sample_indices = sorted(random.sample(range(total_rows), sample_size))

# Paso 5: Leemos filas seleccionadas | PyArrow no soporta directamente random access,
# por eso usamos Pandas como alternativa
table = dataset.to_table()
df = table.to_pandas()
```

Junto con la anteriormente mencionada librería pandas, para este primer análisis de datos también se hizo uso de distintas librerías de visualización como matplotlib, seaborn o plotnine. Por su parte, la realización de consultas SQL espaciales y la generación de ficheros geojson y geopackage fueron, en primer lugar, implementadas en QGIS y luego exportadas en dichos ficheros. Después, se usó la librería geopandas de python para realizar todo el análisis espacial cruzando los datos geográficos con los datos de negocio.

Por su parte, en lo que se refiere al análisis en sí, se distinguen varias fases: una primera exploratoria sobre la calidad de los datos (missing values, valores incongruentes, etc.), una segunda univariante (distribuciones, estadísticos de dispersión, de posición...), una tercera multivariante (por ejemplo, relaciones entre pares de variables) y, como se ha comentado en el párrafo anterior, un análisis geográfico.

Estas técnicas permitieron identificar patrones relevantes que facilitaron las siguientes fases de análisis.

6.4 Técnicas de visualización

En esta sección trataremos la visualización de datos que es clave para entender, explorar e interpretar los patrones encontrados en los viajes de vehículos de alquiler así como para darles un sentido de negocio. Para este fin, se utilizaron diferentes librerías y entornos adaptados tanto al análisis estadístico como al geoespacial.

Herramientas empleadas

- **matplotlib y seaborn:** fueron las librerías principales a la hora de representar gráficamente relaciones univariantes y multivariantes.
- **plotnine:** en algunos casos con sintaxis basada en ggplot2, facilitó la construcción de casos con una sintaxis declarativa más estructurada.
- **GeoPandas + matplotlib:** se emplearon para el análisis geoespacial y para representar distribuciones espaciales de distintas variables estadísticas aplicadas sobre mapas (a partir de GeoDataFrames).
- **QGIS:** se usó como herramienta especializada para la visualización avanzada sobre capas geográficas y mapas urbanos, así como para la verificación de la correcta implementación de consultas SQL espaciales.

Tipos de visualizaciones aplicadas

- **Univariantes:** los histogramas y diagramas de densidad se usaron para estudiar la distribución de variables clave como la duración del viaje, la distancia y el pago al conductor.
- **Multivariantes:** los diagramas de dispersión (scatterplots) se emplearon para analizar relaciones entre variables numéricas (ej. 'trip time' vs 'trip miles'), incluyendo la codificación por color para incorporar una tercera dimensión.
- **Visualizaciones temporales:** se utilizaron para observar la evolución de la demanda a lo largo del día y de la semana. Detectando picos horarios.
- **Gráficos de sectores o de barras:** se aplicaron, principalmente, a variables categóricas y análisis de limpieza de los datos, así como para hacer comparaciones entre distintos competidores dentro del sector.
- **Mapas temáticos:** los mapas de color, de coropletas y de grafos, resultaron útiles para representar la distribución geográfica de los viajes y visualizar los puntos de recogida y destino.

Estas visualizaciones facilitaron tanto la comprensión exploratoria de los datos, como la posterior interpretación de los resultados. En especial, fueron fundamentales para la identificación de patrones espaciales y temporales no tan evidentes a través de solo un análisis numérico.

6.5 Métodos de Machine Learning

En esta sección se describen los algoritmos de aprendizaje automático utilizados en el estudio, distinguiendo entre enfoques no supervisados (clustering), aplicados con fines exploratorios, y supervisados, empleados para tareas predictivas. Concretamente, se utilizó el algoritmo K-Prototypes para realizar una segmentación exploratoria de los viajes, y una Regresión Lineal por Mínimos Cuadrados como modelo predictivo para estimar la variable 'driver pay'.

6.5.1 Técnicas de clustering

Para el análisis exploratorio de los viajes, se empleó el algoritmo K-Prototypes, una extensión de los métodos K-Means y K-Modes, diseñado para manejar conjuntos de datos que contienen tanto variables numéricas como categóricas. Este algoritmo permite segmentar los datos en grupos homogéneos, facilitando la identificación de patrones y comportamientos similares entre los viajes (Aprilliant [2021]).

Fundamentos del algoritmo

El algoritmo k-Prototypes minimiza una función de coste que combina la distancia euclídea para variables numéricas y una medida de disimilitud para variables categóricas. Esta función de disimilitud entre un punto de datos x_i y un prototipo de clúster v_j se define como:

$$d(x_i, v_j) = \sum_{l=1}^q (x_{il} - v_{jl})^2 + \gamma \sum_{l=q+1}^p \delta(x_{il}, q_{jl})$$

donde:

x_i : observación i-ésima.

v_j : prototipo (centroide) del clúster j.

q : número de variables numéricas.

p : número total de variables.

$\delta(x, y)$: función de disimilitud para datos categóricos (0 si iguales, 1 si diferentes).

γ : parámetro de ponderación entre las partes numéricas y categóricas.

El algoritmo itera asignando cada punto al clúster más cercano según esta medida de disimilitud y actualiza los prototipos calculando la media para variables numéricas y la moda para variables categóricas, hasta que las asignaciones se estabilizan (kprototypes contributors [2025]).

Aplicación en el estudio

En este estudio, se decidió aplicar el algoritmo K-Prototypes debido a las características del conjunto de datos, mezclando variables tales como duración, distancia (numéricas) con zona de recogida o día de la semana (categóricas), entre otras.

Esta segmentación permitió identificar grupos de viajes con patrones similares, lo que facilitó un análisis para cada grupo.

A continuación se muestra una pequeña implementación del algoritmo. Con respecto a los hiperparámetros utilizados, para inicializar el objeto creado, se le asigna el número de clústeres a generar (más adelante se detalla el criterio de elección de este valor) y un 'random state' para poder replicar los resultados. Después, toca ajustar los datos con el método 'fit' y debe quedar de manera explícita cuáles son las variables categóricas (categorical=categorical_indices). Estos son los hiperparámetros necesarios antes de lanzar el algoritmo K-Prototypes. Otro hiperparámetro que se puede incluir es 'init' (init='Huang') como criterio de inicialización.

```
from kmodes.kprototypes import KPrototypes

kproto = KPrototypes(n_clusters=3, random_state=42)
clusters = kproto.fit(df_sample, categorical=categorical_indices)
```


- n_clusters: se determinó siguiendo el criterio del codo.

- categorical: índices de columnas consideradas como variables categóricas.

Determinación del número óptimo de clústeres

La determinación del número óptimo de clústeres K se llevó a cabo mediante el método del codo, evaluando el comportamiento del atributo "cost" proporcionado por el modelo. Como se observa en la imagen 5, el número más claro de clústeres se encontró en $K = 3$, que fue seleccionado como valor óptimo. En este caso, se considera que el atributo "cost" representa la suma total de disimilitudes entre cada observación y el prototipo de su clúster, combinando distancias euclídeas (variables numéricas) y disimilitudes simples (variables categóricas). A diferencia de algoritmos como, por ejemplo, K-Means donde se utiliza la suma de cuadrados intra-clúster (WSS), K-Prototypes no trabaja exclusivamente con un espacio numérico euclídeo, por lo que se considera "cost" como la métrica natural y más adecuada para evaluar la calidad de la segmentación.

Figura 5: Elección del número de clústeres



6.5.2 Algoritmos para métodos de regresión

Para abordar el problema de predicción de la variable objetivo 'driver pay', se ha optado por el uso de un modelo de regresión lineal por mínimos cuadrados (OLS), debido a su interpretabilidad, bajo coste computacional y la posibilidad de analizar los efectos individuales de las variables explicativas sobre la variable objetivo.

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Este enfoque parte de una serie de supuestos clásicos sobre los residuos del modelo, tales como su normalidad, independencia y la homocedasticidad (varianza constante). En este estudio se ha prestado especial atención a evaluar estos supuestos, aplicando diferentes métodos de diagnóstico gráfico y estadístico, como el análisis de residuos o gráficos de dispersión frente a las predicciones.

Los valores óptimos de los parámetros de ajuste se obtienen mediante:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Durante el desarrollo del modelo, se valoró la posibilidad de aplicar transformaciones como la de Box-Cox sobre la variable objetivo con el fin de mejorar la distribución de los errores. No obstante, estas transformaciones no ofrecieron mejoras significativas en la calidad del ajuste, por lo que finalmente se optó por mantener la formulación lineal directa.

$$\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

$$\hat{\sigma}^2 = \frac{1}{n - k - 1} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Adicionalmente, se consideró la posible presencia de heterocedasticidad, es decir, una variación no constante en los residuos, que puede afectar la eficiencia de los estimadores. Ante esta sospecha, se recurrió al cálculo de errores estándar robustos a la heterocedasticidad (White-HC), lo que permite obtener inferencias válidas incluso en presencia de este tipo de errores no estándar.

$$\widehat{\text{Var}}_{\text{HC1}}(\hat{\beta}) = \frac{n}{n - k - 1} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{\Omega} \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}$$

$$\mathbf{\Omega}_{ii} = \hat{\varepsilon}_i^2$$

$$\text{SE}_{\text{HC1}}(\hat{\beta}_j) = \sqrt{\left[\widehat{\text{Var}}_{\text{HC1}}(\hat{\beta}) \right]_{jj}}$$

Los detalles sobre la selección de variables, calidad del ajuste y comportamiento de los residuos se analizan más adelante en las secciones de diseño y evaluación del modelo.

Ventajas y limitaciones de este modelo

Se trata de un modelo simple y rápido de entrenar cuyos resultados son fácilmente interpretables. Es útil para detectar tendencias estructurales y evaluar el impacto de variables individuales. Además, admite su extensión con errores robustos (White-HC) ante heterocedasticidad.

Por contra, es un modelo que puede verse afectado por la presencia de valores atípicos (de ahí el apartado dedicado a la limpieza y tratamiento de los datos) o colinealidad. La validez de la inferencia depende fuertemente de los supuestos del modelo (que los errores sean normales, si hay o no heterocedasticidad, que la colinealidad no sea fuerte, etc.) para poder extraer conclusiones estadísticas de los resultados. Si existen relaciones no lineales o interacciones importantes, el modelo puede infraajustar aparte de no capturar efectos de variables latentes no observadas.

6.5.3 Modelos no paramétricos. Árboles de decisión

Además del modelo lineal, se ha considerado la aplicación de árboles de decisión como enfoque alternativo de regresión. Estos modelos no paramétricos presentan una estructura jerárquica en la que

los datos se dividen de forma sucesiva en función de reglas de decisión basadas en los valores de las variables predictoras. Con este algoritmo, no es necesario hacer asunciones previas que necesiten de transformaciones de variables o supuestos sobre la distribución de errores.

En el contexto de este estudio, los árboles de decisión resultan especialmente útiles por su robustez frente a valores atípicos, su tolerancia a la heterocedasticidad y su capacidad para hacer predicciones altamente interpretables. Además los modelos de árboles individuales permiten visualizar fácilmente el proceso de toma de decisiones y comprender el peso relativo de cada variable mediante el gráfico de importancia de variables (frente a modelos de Ensembles).

Por último, para optimizar la elección de hiperparámetros que caracterizan al modelo del árbol que mejor ajuste los datos se usarán técnicas de validación cruzada (en scikit-learn disponible en la función `GridSearchCV`) que permiten evaluar diferentes combinaciones de parámetros y seleccionar aquella que optimiza el desempeño en los datos de validación.

6.6 Estrategia de división de datos

Justificación del muestreo

Dadas las restricciones computacionales (en algunos casos de la memoria, en otros del disco), en ningún momento fue viable procesar el total de registros disponibles (aproximadamente 20 millones por mes). Por tanto, se adoptó una estrategia basada en técnicas de inferencia estadística, priorizando la representatividad de las muestras sobre el tratamiento masivo de datos.

Estrategia de selección de la muestra principal (1M de registros)

Inicialmente, se extrajo una muestra aleatoria de un millón de registros a partir del fichero `.parquet` original, que posteriormente se transformó en un archivo `.csv` para facilitar su manipulación mediante la librería `pandas`. El proceso de selección de estas muestras se hizo de acuerdo a las ventajas que ofrecía la librería `pyarrow` para tratar ficheros `parquet` y su posterior extracción de registros aleatorios a partir de los metadatos asociados al fichero. Esto elimina la necesidad de aplicar operaciones de escritura y aligera el uso de memoria (evitando así posibles interrupciones del kernel). La forma de proceder se muestra en el código siguiente:

```
import pyarrow.parquet as pq
import pyarrow.dataset as ds

table\_metadata = pq.read_metadata(parquet\_file)
total\_rows = table\_metadata.num\_rows

# Paso 1: Usamos dataset de PyArrow para manejar grandes volúmenes
dataset = ds.dataset(parquet\_file, format="parquet")

# Paso 2: Obtenemos el número total de filas
# (Solo es confiable si los archivos Parquet contienen metadatos actualizados)
table\_metadata = pq.read_metadata(parquet\_file)
total\_rows = table\_metadata.num\_rows

# Paso 3: Definimos el tamaño de la muestra
sample\_size = 1\_000\_000

# Paso 4: Seleccionamos índices aleatorios
```

```
sample\_indices = sorted(random.sample(range(total\_rows), sample\_size))

# Paso 5: Leemos filas seleccionadas | PyArrow no soporta directamente random access,
# por eso usamos Pandas como workaround
table = dataset.to\_table()
df = table.to\_pandas()
```

Muestreo aleatorio posterior (20K):

La selección de un muestreo aleatorio de muestras con 20.000 observaciones a partir de aquellos datos que fueron limpiados y preprocesados del millón anterior, se justifica tras la realización de distintos experimentos con diversos tamaños de muestra (10K, 100K, 500K), evaluando mediante remuestreo de tipo bootstrap la estabilidad de la media y la varianza de las variables clave. Se observó que con 20.000 registros se lograba un equilibrio óptimo entre capacidad inferencial y eficiencia computacional.

Cluster	10K muestras		1M muestras		14M muestras	
	elementos	Distancia ^a	elementos	Distancia ^a	elementos	Distancia ^a
0	32%	$101 \cdot 10^3$	31%	$98 \cdot 10^3$	31,16%	$101 \cdot 10^3$
1	61%	$58 \cdot 10^3$	63%	$56 \cdot 10^3$	61,68%	$56 \cdot 10^3$
2	7%	$642 \cdot 10^3$	6%	$559 \cdot 10^3$	7,16%	$899 \cdot 10^3$
Tiempo	15 sec		27 min		7 h	

^a Distancia media al centroide

Table 4: Comparativa de resultados de clustering con diferentes tamaños de muestra

En la tabla 4 se muestra un ejemplo de comportamiento para distinto números de muestras extraídas para el caso de Mayo de 2021 (14 millones de viajes en total). Se trata de una aplicación de un algoritmo de K-Prototypes (se verá más adelante, en esta memoria) a muestras de distintos y a la población completa, y se comprueba que tanto la proporción de elementos como las distancias a los centroides no varían demasiado entre sí. Este fue uno de los resultados que sirvió –junto a otros mostrados más adelante– para tomar en consideración la selección de una muestra que pueda inferir bien las características de la población completa.

Más adelante, como se irá viendo, el tamaño de la muestra aleatoria se fue ajustando para que esta fuese representativa, rápida de procesar y no produjeran bloqueos en el kernel como el señalado en el mensaje:

The Kernel crashed while executing code in the current cell or a previous cell.

Please review the code in the cell(s) to identify a possible cause of the failure.

Click

View Jupyter

A continuación, se muestran las proporciones diarias/horarias de viajes resultantes para 50 iteraciones de bootstrap con tamaños de muestra 10.000 y 20.000 observaciones, respectivamente. Como

se observa, el aumento del tamaño de las muestras conduce a una reducción de la variabilidad, manteniendo los valores medios. El resultado global es una mayor estabilidad en los estimadores al pasar de muestras de tamaño 10K a otras de tamaño 20K, junto con un aumento del coste de cálculo no demasiado elevado, por lo que consideramos este último tamaño como óptimo para realizar el análisis.

Las figuras 7 y 9, correspondientes a muestras de 20.000 observaciones, permiten visualizar la mejora del comportamiento frente a las muestras con 10.000 observaciones, recogidas en las figuras 6 y 8, y validar así el tamaño de la muestra aleatoria seleccionada tras remuestreo de bootstrap. Las variables utilizadas para identificar visualmente el comportamiento del remuestreo bootstrap son las que corresponden con los días de la semana y horas de recogida (Pick-Up).

Figura 6: Remuestreo bootstrap semanal sobre Pick-Ups (muestras de 10K)




Figura 7: Remuestreo bootstrap semanal sobre Pick-Ups (muestras de 20K)




Figura 8: Remuestreo bootstrap diario sobre Pick-Ups (muestras de 10K)





Figura 9: Remuestreo bootstrap diario sobre Pick-Ups (muestras de 20K)



Muestra aleatoria estratificada para modelo de predicción

Para el modelo de predicción, los datos de entrada se eligieron mediante un muestreo aleatorio estratificado. Para esta estratificación, se usaron como punto de partida los resultados del análisis de clústeres obtenido más adelante (ver 7.4). Las proporciones obtenidas se utilizaron como referencia para seleccionar la muestra de 20.000 observaciones estratificadas.

División train-test (80%-20%)

Sobre esta muestra aleatoria estratificada de 20.000 observaciones, se aplicó una división estándar en conjunto de entrenamiento y test (80%-20%) para el entrenamiento y evaluación de los modelos.

Aplicación del modelo a otras muestras de 20K

Una vez validado el rendimiento del modelo, se probó su generalización repitiendo el proceso sobre

distintas muestras aleatorias estratificadas adicionales de 20.000 registros extraídas del mismo conjunto inicial de 1 millón. Todo ello para asegurar la validez y estabilidad del modelo.

Ampliación del modelo a otros meses como validación temporal

Finalmente, con el objetivo de evaluar la estabilidad temporal del modelo, se replicó la aplicación del mismo a datos correspondientes a otros meses del año, observando su comportamiento y capacidad de generalización en diferentes contextos temporales.

6.7 Justificación de las herramientas y tecnologías elegidas

Para el desarrollo del presente trabajo de ciencia de datos, se ha requerido el uso de diversas herramientas y tecnologías, tanto para la exploración y el análisis de los datos como para la implementación de modelos predictivos. La elección de cada una de ellas se correspondió con criterios de eficiencia, versatilidad, manejo, conocimiento y soporte para análisis espacial.

Lenguaje y entorno de programación

- **Python:** lenguaje utilizado, gracias a su riqueza en librerías especializadas en ciencia de datos.
- **Notebooks de Jupyter** desarrollados localmente en Visual Studio Code. En las situaciones en las que se requirió mayor disponibilidad de memoria RAM o de almacenamiento, se compaginó con los entornos proporcionados por Google Colab y Kaggle.

Librerías y otras herramientas manejadas:

- **PyArrow:** para la extracción y conversión de ficheros .parquet.
- **Pandas:** para cargar, limpiar y manipular datos.
- **Numpy:** para el cálculo numérico y por su soporte para arrays y operaciones vectorizadas.
- **Scipy:** para la aplicación de tests estadísticos y por su soporte para transformaciones de datos.
- **Scikit-learn:** para el preprocesamiento de datos, detección de outliers, clustering y modelado predictivo.
- **Statsmodels:** para el modelado estadístico y el contraste de hipótesis, y para el análisis de modelos de regresión.
- **Matplotlib, seaborn, plotnine:** para la generación de visualizaciones estadísticas.
- **Geopandas:** para el tratamiento de datos georreferenciados y generación de mapas.
- **Networkx:** para el análisis exploratorio de relaciones mediante grafos.
- **QGIS:** como herramienta de escritorio para análisis geoespacial avanzado, generación de consultas espaciales y ficheros .geojson y .geopackage.

Durante el desarrollo se evaluaron los compromisos entre capacidad de almacenamiento y memoria RAM (necesaria para cargar y procesar grandes conjuntos de datos). Esto motivó a reorientar el trabajo hacia la aplicación de conocimientos de inferencia estadística, la toma de muestras aleatorias, y a su validación mediante remuestreo bootstrap para asegurar que no se comprometía la representatividad estadística.

El uso combinado de estas herramientas y la aplicación de conocimientos, permitió abordar todas las fases del proyecto.

7 Análisis Exploratorio


Antes de construir el modelo predictivo, se realizó un análisis exploratorio de los datos con el objetivo de comprender su distribución, su comportamiento y su estructura. Este análisis permitió detectar patrones relevantes, identificar valores atípicos, evaluar la presencia de missing values, y explorar relaciones entre variables tanto numéricas como categóricas. A través de distintas visualizaciones y estadísticas descriptivas, se extrajeron las primeras conclusiones que fundamentaron las decisiones en la limpieza, ingeniería de características y selección del modelo.

7.1 Caracterización general de los viajes

Un primer grupo de gráficos que se muestran en este trabajo son los referidos al carácter temporal y espacial de los viajes. En la figura 10 se muestra una desagregación por cada día de la semana para cada franja horaria. Esto consigue una mayor interpretabilidad y darle un mayor sentido que hacerlo sobre el volumen total (ver figura 11).


Distribución temporal

Figura 10: Distribución de viajes por franja horaria desagregado por días de la semana



Aquí se pueden ver a simple vista los picos de tráfico (y demanda) que se observan en las mañanas en los días laborables (muy probablemente, viajes hacia el trabajo), un valle en las horas centrales y otro aumento en las horas de salida del trabajo (15h-18h). Los viernes (línea morada) se observa que, aunque hay menos viajes que el resto de días de entre semana por la mañana, hay más viajes hacia la noche (ocio nocturno). Por su parte, los fines de semana tienen alta frecuencia de uso en las horas de la madrugada, disminuyen por la mañana para volver a subir por las tardes. Más adelante, en la subsección 7.4 dedicada a la segmentación y análisis exploratorio de clústeres se ahondará la interpretación de patrones de viajes en lo referido a la franja horaria más común.

Figura 11: Distribución de viajes por franja horaria



Distribución espacial

Como en el caso del análisis temporal, para un sector como es el de la movilidad y para compañías de servicio de transporte privado, es importante tener una noción del territorio y de como se comportan los distintos actores del sector en relación a este. Las diversas herramientas orientadas al análisis geoespacial permiten obtener una visión integral del territorio a fin de poder tomar decisiones basadas en geodatos. Las figuras que se muestran en este apartado (por ejemplo, la figure 12), en muchos casos muestran valores en términos absolutos. Esto hace que aquellos polígonos geográficos con mayor tamaño de área en zonas urbanas acaparen más viajes en total. En la sección 7.4 también se incide en la densidad de vehículos por milla cuadrada. En este segundo tipo de métrica, se observará que las zonas con mayor demanda por milla cuadrada se encuentra en Manhattan. La figura 12 muestra el número de puntos de recogida (pick-up) de cada carrera en FHV registrada. Destacan los dos aeropuertos de Queens, muy ligados con el servicio intermodal de última milla que suelen proporcionar el ridehailing, así como algunas zonas de Manhattan y Brooklyn. La figura 13 muestra todas las localizaciones de origen (Pick-Up Location) ordenadas de más viajes a menos. En la figura (13) se muestra con mayor detalle esas localizaciones ordenadas.

Figura 12: Localizaciones de recogidas (Pick-Ups)






Figura 13: Pick-Ups ordenados
Number of Trips by Pick-Up Location ID



En la figura 14 se muestran las treinta localizaciones con mayor recogida de usuarios, y en la tabla 5 se desglosa el top 10 de las mismas.

Figura 14: Top 30 Pick-Ups



LocationID	Zona	Borough	Trip Counts
138	LaGuardia Airport	Queens	20,786
132	JFK Airport	Queens	19,169
61	Crown Heights North	Brooklyn	12,922
79	East Village	Manhattan	12,843
230	Times Sq/Theatre District	Manhattan	12,371
161	Midtown Center	Manhattan	11,955
231	TriBeCa/Civic Center	Manhattan	11,647
68	East Chelsea	Manhattan	11,565
246	West Chelsea/Hudson Yards	Manhattan	11,327
164	Midtown South	Manhattan	10,801

Table 5: Localizaciones de origen más comunes para muestras de 1M - Mayo 2024

En general, los lugares de donde parten más viajes son los principales aeropuertos de la ciudad: LaGuardia y JFK. Después aparecen distintas zonas de Manhattan con mucha densidad o de Brooklyn, con polígonos de tamaño grande en zonas urbanas. Esto coincide con lo mencionado anteriormente. Manhattan, como centro de atracción turística y de consumo, así como de actividad económica, atrae a una gran densidad de población que, en parte, aprovecha los servicios de FHV. Más adelante se verá también que son un medio de transporte para abandonar esta zona y volver a los lugares de residencia, posiblemente tras un periodo de tiempo en la zona (en especial en los viajes registrados los fines de semana por la tarde). Sin embargo, con mucha diferencia, los aeropuertos son los destinos (y orígenes) más comunes con lo que refuerzan la idea de que los servicios de ridehailing son utilizados como medio de última milla para otros servicios de transporte. Como inciso, no se ha comprobado en este trabajo si el mismo comportamiento sucede con grandes estaciones de ferrocarril.

Figura 15: Mapa Drop-Offs





Figura 16: Top 30 Drop-Offs
Number of Trips by Drop-Off Location ID



En el caso de los destinos, se observa que la mayoría de viajes son afuera de los límites administrativos de la ciudad. En este caso se trata de la localización identificada como '265' pero sin polígono geográfico al que ser asignado por la TLC. Como se mencionó en la sección 6.2, aquellos campos con missing values, se nombraron como parte del distrito "Out of City". Más adelante, en el análisis

de grafos que se presenta en la sección 7.3 se les asignará un lugar arbitrario en el mapa. El resto de localizaciones más demandas como destino del trayecto se siguen encontrando en los aeropuertos, Manhattan y zonas de Brooklyn.


El hecho de que la localización de destino más común sea "fuera de la ciudad" refuerza varias de las conjeturas anteriores: viajes de regreso a la periferia tras volver del trabajo (viajes más comunes por las tardes entre semana), tras una tarde de ocio en el centro de Manhattan (Times Squares, por ejemplo) o transbordos de viaje en avión, compatibles con el regreso del trabajo. Esta afluencia de viajes, servirá más adelante para imputar esta localización en la zona de Nueva Jersey. Es decir, son viajes largos, a zonas residenciales pero con media-alta densidad.

Pese a que a primera vista pueda carecer de la misma relevancia saber cuáles son los destinos que los orígenes de la demanda (desde un punto de vista para el negocio del ridehailing), estos pueden servir para observar patrones geospaciales correlados, para una anticipación de la demanda o para intentar reducir el trayecto que se debe hacer para llegar al siguiente usuario.

Análisis de demanda

Un aspecto meramente exploratorio es conocer cuántos viajes se realizan en una misma zona (ver figura 17). Aunque este aspecto podría ganar más información si se realizase sobre viajes dentro de un mismo distrito (Borough). De todos modos, se observa que solo el 6,7% de los viajes se realizan dentro de una misma localización y, como se muestra en el mapa de la figura 68, incluida en el anexo, se dan en aquellos polígonos de área grande en zonas urbanas (especialmente en Brooklyn y Queens). Es decir, a fin de cuentas lo que más influye en este resultado es, simplemente, el tamaño del polígono asignado.


Figura 17: Trayectos en la misma zona vs diferente zona
Proportion of Trips with Same Pick-Up and Drop-Off Locations



En este análisis de demanda, es interesante también observar cuál es la cuota de mercado por compañía para datos estudiados durante el mes de mayo de 2024. Tal y como se muestran en la figura 18, tres cada cuatro viajes que son contratados lo son con vehículos vinculados a Uber, mostrándose así la alta implantación en el territorio que lleva teniendo la compañía desde los últimos años. Por su parte, la tabla 6 muestra el número absoluto de viajes en la muestra proporcional (recordemos que debido a las limitaciones a la hora de procesar la ingente cantidad de datos, se decidió tomar muestras de 1 millón de elementos para analizarlas).

Por otro lado, se recuerda que en este estudio solo se evalúan aquellos servicios de FHV capaces de registrar un mínimo de 10.000 viajes diarios (en total) y quedan excluidos los registros de taxis.

Figura 18: Comparación de cuota de mercado entre compañías FHV




License Number	Company	Vehicle Count
HV0003	Uber	751,384
HV0005	Lyft	248,616

Table 6: Vehicle License Data for Ride-sharing Companies

En la figura 19 se desagrega el número de pick-ups (o recogidas) que realiza cada compañía y por hora. A la vista de los resultados, se observa que en todas las franjas horarias domina Uber sobre Lyft, las dos principales compañías del sector. Como apunte interesante, Lyft consigue su pico de actividad en las horas de la mañana, mientras que Uber supera su propio pico de la mañana, por la tarde, indicando ciertos patrones de comportamiento de los usuarios de cada compañía. Un motivo que pueda indicar un mejor desempeño relativo de Lyft por la mañana quizá sea su conocimiento por parte de la audiencia más orientada al trabajo o la actividad económica o que provea servicios específicos para ello, mientras que Uber sea una marca más conocida a nivel global, destacando especialmente en sectores de la población orientada al consumo y al ocio.

Figura 19: Número de Pick-Ups desagregado por franja horaria y compañía FHV



Ahora bien, como se ha visto antes, también es importante hallar un patrón de comportamiento y un análisis por compañía a nivel espacial y saber dónde se demanda más cada servicio, y en qué zonas del territorio se impone una compañía y por cuánto.

A estas preguntas se responden en los mapas disponibles en las figuras 20 y 21. A nivel geográfico, se observa, que al igual que en términos generales, las zonas con mayor demanda de este tipo de servicios se encuentran principalmente en los aeropuertos y, después, en zonas de Manhattan y Brooklyn.

Figura 20: Servicio FHV dominante por localización de recogida (Pick-Up)





Figura 21: Comparativa por dominio territorial entre distintas compañías FHV



Qué compañía se impone en cada localización, se ve en el conjunto de mapas de la figura 20. En el primer mapa, se impone el color negro de Uber, salvo en un polígono de Queens (Saint Michaels Cemetery/Woodside, 207) próximo al aeropuerto de LaGuardia (138). Dado que en un primer momento se consideró como una posible anomalía, se decidió observar cuál era la diferencia en términos absolutos y en términos porcentuales. Los dos siguientes mapas de la figura muestran que en términos absolutos es baja la diferencia entre unos servicios y otros, no así la diferencia en términos porcentuales. De esto se deduce que, en ese caso particular, no se trata de una zona con demasiados orígenes (pick-ups) de viajes para este tipo de servicio en comparación con otras zonas más concurridas.

Análisis por distrito (Borough)

Hasta el momento, el análisis geográfico se ha dado al máximo nivel de detalle (los polígonos con LocationID). Sin embargo, es muy posible que sea más sencillo de seguir si se disminuye ese nivel de detalle y se integran en zonas de la ciudad más reconocidas: los distritos (en inglés: Boroughs). Los cinco que componen la ciudad de Nueva York son: Manhattan, Brooklyn, Queens, Bronx, Staten Island más el aeropuerto de Newark. Por otro lado, tal y como se ha mencionado en secciones anteriores (véase la sección 6.2), se incluyó un nuevo campo ad hoc "Out of City" para tratar aquellos viajes con origen o destino fuera de los límites de la ciudad.

Figura 22: Pick-Ups por distritos o boroughs





Figura 23: Drop-Offs por distritos o boroughs



En la figura 22 se observa tanto el número de viajes absolutos de la muestra como la distribución en porcentajes para cada origen del viaje. Pese a que con estos datos no se puede desagregar por día de la semana o por franja horaria, se tiene una idea básica de cuáles son las zonas con mayor demanda. En este caso, caso el 40% de los viajes se toman en Manhattan, frente a un 26% en Brooklyn y un 21% en Queens (que es donde se encuentran los principales aeropuertos de la ciudad).

Sin embargo, si comparamos estos resultados con la figura 23, vemos que el número de destinos baja en Manhattan (36,7%) y sube en Brooklyn (27,2%), Queens (21,7%) y fuera de la ciudad. Más adelante, en el análisis de la segmentación (7.4), se ahondará más en este comportamiento pero que puede ser muy típico. Pero se puede intuir lo comentado anteriormente: un número considerado de usuarios viaja a Manhattan en un medio alternativo a los servicios de FHV y regresa a sus lugares de residencia (fuera de Manhattan) en este tipo de servicios. O simplemente, coincide más el horario pico de regreso frente a unos viajes de ida más esparcidas a lo largo del día.

7.2 Identificación de patrones relevantes


Tras una primera parte centrada en el análisis general del sector y la situación del mercado de los servicios FHV en la ciudad de Nueva York, se procede a una fase de análisis estadístico más detallado. En esta etapa, se examinan individualmente las variables con potencial utilidad para el modelo de aprendizaje automático que se desarrollará en secciones posteriores.

Distribuciones univariantes

En primer lugar, se realiza un análisis de cada una de aquellas variables numéricas continuas para observar cuál es la naturaleza de la distribución: si siguen una distribución normal, si tienen algo de asimetría, cuánto se separan unos valores del resto, etc. Nótese que en las figuras (y sobre todo, en las tablas), no aparece aplicado el tratamiento de outliers expuesto en la sección 6.1).

La figura 24 muestra la distribución (en frecuencia relativa) de una de las variables principales: 'trip miles'.

Figura 24: Variable Trip Miles



Esta variable numérica debe tener sus valores positivos y tiene una asimetría positiva (la media es un poco mayor que la mediana debido a la influencia de los datos de la cola). Por su parte, se proporciona la tabla 7 desagregando por compañía. Y sirve para ver si existe alguna diferencia entre las mismas.


hvfhs_license_num	count	mean	std	min	25%	50%	75%	max
Uber	751.384,0	5,103	5,899	0,0	1,580	3,030	6,390	326,350
Lyft	248.616,0	5,302	6,056	0,0	1,658	3,1465	6,683	146,594

Table 7: Estadísticas descriptivas de trip_miles por compañía

Del millón de viajes aleatorios durante el mes de mayo 2024, se observaron que el viaje mediano recorrió 3 millas frente a las 5,15 millas del medio. Esto, junto con el valor de la desviación estándar

indican de manera cuantitativa cierta asimetría positiva en la distribución de las distancias recorridas para cada viaje.

Figura 25: Variable Trip Time



hvfhs_license_num	count	mean	std	min	25%	50%	75%	max
Uber	751.384,0	1253,815	927,667	4,0	612,0	1003,5	1613,5	20.661
Lyft	248.616,0	1291,874	943,035	1,0	648,0	1037,0	1648,0	18.950


Table 8: Estadísticas descriptivas de 'trip time' por compañía

La figura 25 y la tabla 8, por su parte, analizan la variable temporal 'trip time'. De las dos variables se concluye que la mayoría de viajes suelen tener una duración de unos veinte minutos y recorren, en media, cinco millas. Se observa que, correctamente, ninguna carrera tiene valores negativos en estos campos.

Las distribuciones de cola pesada suelen mostrar una influencia en los datos de mayor valor, mostrando ciertas disyuntivas a la hora de si considerar ciertos valores como parte de esa cola progresiva o directamente como outliers. No obstante, según se observan en las tablas 7 y 8, la gran diferencia entre los valores que representan el percentil 75 y el valor máximo, son grandes indicadores de la presencia de outliers.

Las variables de la figura 26 se refieren a pequeños recargos que pueden considerarse como influyentes a la hora de determinar un viaje (especialmente si van a aeropuertos y deben recorrer vías de alta capacidad con peaje). Suelen ser variables con pocos valores (casi discretos u ordinales en algunos casos) que pueden ser interesantes a la hora de modelar. Por su parte, la tabla 9) da una información sobre las distintas variables booleanas. Estas variables suelen indicar el régimen del servicio: si es compartido, si es para persona con movilidad reducida... Pese a ser muy desbalanceados, también se estima su importancia a la hora de diseñar el modelo.

Figura 26: Variables numéricas



Variables booleanas:


Value	shared_request	shared_match	access_a_ride	wav_request	wav_match
No	96,28%	98,61%	99,92%	99,72%	90,95%
Yes	3,72%	1,39%	0,08%	0,28%	9,05%

Table 9: Distribución de variables booleanas en datos de viajes

Variable objetivo

Tras realizar un análisis estadístico del resto de variables, en este apartado se procede a analizar **driver pay**. Esta variable en secciones posteriores va a servir como target del modelo a predecir. Pese a todo, aquí solo se realiza un pequeño análisis estadístico de la variable y no sobre su significado (véase 5.2) o sobre su interpretación técnica (véase 8.1).

Figura 27: Variable Driver Pay



hvfhs_license_num	count	mean	std	min	25%	50%	75%	max
Uber	751.384,0	20,82	17,76	-33,88	9,22	15,50	26,20	851,46
Lyft	248.616,0	20,89	17,86	5,47	9,16	15,36	26,36	443,09

Table 10: Estadísticas descriptivas de 'driver pay' por compañía

En este caso, al tratarse de la variable objetivo, es importante observar la distribución de la misma. Al igual que en las variables 'trip time' y 'trip miles', la variable 'driver pay' muestra un comportamiento con asimetría de cola pesada. Los valores negativos mostrados en la tabla 10 son tratados de acuerdo a lo expuesto en la sección 6.1. Sobre la misma tabla es importante resaltar que no hay diferencias estadísticas entre el comportamiento en la variable para cada compañía. Esto quiere decir que la variable 'hvfhs license num' no se tendrá en cuenta a la hora de diseñar el modelo porque no se considera relevante para predecir 'driver pay'. A nivel cuantitativo, los viajes tienen un coste medio de \$20 y uno mediano en torno a los \$16. Es un valor interesante, que puede servir para otros estudios y que en este caso, da una noción y contexto al acuerdo de mínimos aprobado por la TCL New York City Taxi and Limousine Commission [2018b] por la que la cantidad mínima de remuneración al conductor sean \$17,22/hora.

Relaciones bivariantes y multivariantes

Tras una primera evaluación de las variables numéricas por separado (análisis univariante), es importante observar las relaciones que tienen entre sí las distintas variables. No solo para el caso de variables numéricas, sino combinando también con variables categóricas. Por ejemplo, en las figuras 29 y 30 se muestran características (en distancia y tiempo) de los viajes por cada franja horaria (Pickup Hour).

Figura 28: Relación entre 'trip time' y 'driver pay'





Figura 29: Duración media del viaje por hora de recogida





Figura 30: Distancia media del viaje por hora de recogida

En la figura 29, se observa que hay una mayor cantidad de viajes largos a las cinco de la madrugada de cada día. Teniendo en cuenta lo visto en la figura 10, estos viajes deben corresponder a casos especiales que recorran largas distancias. Posiblemente se traten de viajes que vayan de fuera de la ciudad (Nueva Jersey) a los aeropuertos de LaGuardia o JFK.

Por su parte, la figura 30 permite observar las horas pico de tráfico y los posibles cuellos de botella. Dado que, como en el caso anterior, están integrados todos los días de la semana sin diferenciar entre fin de semana y día laborable, se observa una mayor actividad de FHV por las tardes, coincidiendo tanto como la salida de la jornada laboral, como momentos de ocio por la tarde del fin de semana. Y además, por eso el total de tráfico acumulado por la tarde (en torno a las 15h-17h) es mayor que por las mañanas (donde los fines de semana, la actividad cae mucho). La figura 31 da una perspectiva geográfica del tiempo medio por viaje en cada zona. En ella se puede observar que el aeropuerto del JFK (id = 132) tiene mayores tiempos de espera, seguido de LaGuardia (138) y algunas zonas específicas de Brooklyn.

Figura 31: Mapa con tiempos medios por trayecto según punto recogida (Pick-Up)



7.3 Análisis estructural (Grafo y sentido de los trayectos)

Dentro del análisis exploratorio, también se consideró interesante estudiar los comportamientos de los viajes mediante la representación de un grafo. Se consideraron los distintos puntos o localizaciones (LocationID) como los nodos del mismo y cada viaje entre un nodo origen y destino como la arista.

En la primera imagen (32) se observan los viajes de la red hacia la zona de Manhattan. Esto permite una visualización con mayor facilidad sobre las zonas más densas en demanda de servicios FHV y con más densidad de 'población de hecho'¹. Por su parte, la figura 33 integra las aristas y viajes del primer grafo (ver 32) en distritos o boroughs. Esta simplificación permite observar de manera clara el flujo de viajes interdistritales e intradistritales.

Como se observa en la figura 33, la mayoría de viajes se concentran entre -sobre todo- Manhattan, Queens y Brooklyn. Bien es cierto, que estos grafos no están desagregados por día de la semana o franja horaria, lo cual podría aportar mayor valor al estudio y caracterizar el mapa en función del flujo de viajes que hay en las distintas zonas de la ciudad.

¹explicar qué es la población de hecho

Figura 32: Viajes FHV para Manhattan






Figura 33: Viajes FHV por distritos/boroughs



En el grafo de la figura 34 se muestran los trayectos en función de la remuneración del conductor (driver pay). Para su visualización, se han excluido aquellos trayectos por debajo de la remuneración mediana. A destacar algunos viajes de larga distancia o que van a zonas de Staten Island o afuera de la ciudad.

Figura 34: Viajes identificados por valores de 'driver pay' por encima de la mediana remuneración por trayecto (por encima del driver pay mediano)




Por último, los grafos que se muestran en las figuras 35 y 36 sirven para determinar dónde se encuentran situados los principales aeropuertos de la ciudad (JFK, LaGuardia, Newark) y qué lugares se relacionan más con estos. Por otro lado, se incluye el nivel de recargo por peaje para cada trayecto, observándose que son aquellos que tienen más recargo por peajes los que viajan a Nueva Jersey (hacia el oeste, cruzando el río Hudson). Estos dos mapas pueden servir a la hora de orientar el objetivo del estudio en los que se tengan en consideración alguna de estas variables o circunstancias particulares de los viajes.

Como apunte a destacar, dado que como se comentó en la sección 6.2, había ciertas localizaciones que quedaban fuera de los límites administrativos de la ciudad de Nueva York, por lo que la TLC no las incluía en su información geográfica. En estos casos se tomó la decisión de asignar un valor en Long Island y otro (la mayoría de los viajes) en Jersey City (Nueva Jersey). Esto se basa en el estudio de comportamiento de los viajes y las características demográficas.

Figura 35: Grafo con trayectos que incluyen 'airport fees'



Figura 36: Grafo con trayectos que incluyen pago de peajes (tolls)



7.4 Segmentación exploratoria mediante clustering

Con el objetivo de identificar posibles patrones ocultos sobre los comportamientos de los viajes y poder segmentarlos en grupos homogéneos, se ha aplicado una técnica de clustering no supervisada basada en el algoritmo de K-Prototypes. Como se describió en la sección 6.5.1, este método resulta adecuado para conjuntos de datos mixtos que combinan variables numéricas y categóricas. La aplicación de esta técnica sobre una muestra representativa ha permitido identificar tres clústeres diferenciados, que ofrecen una visión exploratoria del comportamiento de los servicios FHV en la ciudad de Nueva York. Esta segmentación, aparte de dar información sobre las tipologías de los viajes, permite organizar una posterior selección muestral estratificada para entrenar modelos de predicción (véase la sección 8).

Centroides y distribución de los clústeres

En la tabla 11, se muestran las coordenadas que definen a cada uno de los centroides calculados a partir del algoritmo K-Prototypes. Tras ejecutar el algoritmo con la semilla `random_state` fijada en 42, el porcentaje de elementos correspondientes a cada clúster fue de: 31,06% para el clúster 0, 61,53% para el clúster 1 y 7,42% -para el clúster 2-.

Variable	Cluster 0	Cluster 1	Cluster 2
trip_miles	7.6015	2.4188	17.2076
trip_time (s)	1771.87	711.52	3665.77
tolls	0.2251	-0.2506	1.1363
congestion_surcharge	0.2047	-0.1308	0.2282
airport_fee	0.1698	-0.2284	1.1842
driver_pay	29.2545	11.3642	63.1894
PULocationID	138	76	132
DOLocationID	265	61	265
shared_request_flag	N	N	N
shared_match_flag	N	N	N
access_a_ride_flag	N	N	N
wav_request_flag	N	N	N
wav_match_flag	N	N	N
pickup_datetime_dayofweek	4	4	2
dropoff_datetime_dayofweek	4	4	3
pickup_datetime_hour	19	22	16
dropoff_datetime_hour	19	22	17

Table 11: Centroides representativos de los tres clústeres generados con K-Prototypes

Análisis temporal y validación básica por remuestreo

Para garantizar la calidad de la selección de la muestra, se aplicaron técnicas de bootstrap, con el objetivo de validar la estabilidad de los clústeres obtenidos. Esta estrategia permitió, además, justificar empíricamente la elección de un tamaño muestral de 20.000 observaciones, como ya se detalló previamente en la sección 6.6

La figura 37 muestra el valor medio obtenido para cada clúster a lo largo de una semana tras ejecutar las iteraciones definidas mediante bootstrap. Las figuras 38, 39 y 40 corresponden a las iteraciones del remuestreo bootstrap ejecutadas para cada clúster. Nótese la línea marcada en negro que se corresponde con el valor medio para cada día de la semana y que es exactamente la misma línea que se ve en la figura 37 para cada clúster. Con 20.000 observaciones se demuestra que la variabilidad

queda dentro de unos márgenes aceptables para trabajar con este tamaño de muestras.

Figura 37: Media clúster semanal




Figura 38: cluster 0 bootstrap semanal




Figura 39: cluster 1 bootstrap semanal






Figura 40: cluster 2 bootstrap semanal



En la figura 40 se observa que las muestras del clúster 2 tienen mayor variabilidad, especialmente en los días del viernes. Se puede pensar que quizá se corresponda con límites en franjas horarias que coinciden: salidas del trabajo por la tarde con franja de ocio.

Figura 41: Media clúster por horas



La comprobación de la calidad de las muestras –mediante remuestreo bootstrap– con las horas del día por clúster (figura 41) se encuentra recogida en la sección 11 de Anexos.

Validación de los clústeres

Para comprobar la estabilidad de la segmentación obtenida mediante clustering, se realizó una validación adicional sobre muestras aleatorias de 20.000 registros correspondientes a distintos meses del año 2024. Se aplicó el mismo algoritmo (K-Prototypes) con idéntica configuración y número de clústeres. Los resultados obtenidos mostraron una estructura similar en cuanto a proporciones de asignación y características de los centroides. Esta validación respalda la consistencia de los clústeres y justifica su uso como elemento interpretativo en el análisis.

Se ha podido validar la estabilidad y robustez de los clústeres mediante su generalización sobre muestras aleatorias de 20.000 observaciones sobre los siguientes meses de 2024: enero, marzo, mayo, agosto, septiembre y diciembre de 2024.

En todos los casos, los clústeres muestran proporciones estables: 59-61% para el clúster mayoritario, 30-32% para el clúster mediano y 7-9% para el clúster minoritario, así como valores promedios consistentes en variables clave como 'trip miles', 'trip time' y 'driver pay', lo que demuestra una estructura clara y replicable. Con estos resultados, se puede dar por válida la generalización sobre la población completa.

Interpretación de los clústeres

Una vez validado tanto el método de estimación de los clústeres como el tamaño muestral utilizado para su cálculo, se procede a describir con detalle las particularidades que caracterizan a cada grupo, representadas por sus respectivos centroides. Dado que el algoritmo K-Prototypes maneja variables categóricas utilizando la moda como valor representativo, lo que puede inducir a interpretaciones ambiguas, se complementa el análisis con una interpretación con base temporal y geográfica de cada clúster, facilitando así su interpretabilidad.

La tabla 12 muestra las proporciones relativas de 'Síes' y 'Noes' para las distintas variables booleanas. En todos los casos, el desbalanceo es evidente, por lo que hay que fijarse en la clase minoritaria para saber en qué clúster hay más viajes según en qué condiciones.


shared_request_flag	Cluster 0	Cluster 1	Cluster 2
N	0.958461	0.963514	0.962913
Y	0.041539	0.036486	0.037087
shared_match_flag	Cluster 0	Cluster 1	Cluster 2
N	0.975849	0.992605	0.971005
Y	0.024151	0.007395	0.028995
access_a_ride_flag	Cluster 0	Cluster 1	Cluster 2
N	0.998551	0.999675	0.998651
Y	0.001449	0.000325	0.001349
wav_request_flag	Cluster 0	Cluster 1	Cluster 2
N	0.997424	0.997806	0.995954
Y	0.002576	0.002194	0.004046
wav_match_flag	Cluster 0	Cluster 1	Cluster 2
N	0.915634	0.902162	0.930546
Y	0.084366	0.097838	0.069454

Table 12: Distribución de valores binarios por clúster en variables categóricas

En la figura 42 se muestran las variaciones en puntos porcentuales por distrito para orígenes (Pick-Ups) de viajes por clúster. Y en la figura 43 se muestra el resultado análogo para destinos (Drop-Offs).


A primera vista se observa un mayor número de viajes (respecto de la media) que parten de Manhattan para el clúster 0. Para el clúster 1, sin embargo, hay menos viajes desde Manhattan respecto de la media y más desde el Bronx y Brooklyn. Por su parte, para el clúster 2, hay muchos más viajes (11 puntos por encima de la media) de Queens, el distrito en el que se encuentran los principales aeropuertos de la ciudad.

Figura 42: Desviación respecto de la media para origen



Por el otro lado, respecto a los destinos de esos viajes. La figura 43 facilita su interpretación de la variabilidad respecto de la media. Para el clúster 0, hay un porcentaje similar de viajes para cada distrito que para la media (siendo inferior en el Bronx, $-2,9\text{pp}$ y superior en Manhattan, 1pp , y 'Out of City' $1,9\text{pp}$). Para el clúster 1, por su parte, se observan algo menos de viajes a 'Out of City' ($-2,87\text{pp}$) y más con destino al Bronx ($2,34\text{pp}$). En último lugar, el clúster 2 se caracteriza por tener un fuerte incremento de viajes hacia fuera de la ciudad (Out of City, $15,87\text{pp}$ por encima de la media) y el distrito de Queens ($4,68\text{pp}$). En cambio, bajan considerablemente respecto de la media en el Bronx ($-8,12\text{pp}$), Brooklyn ($-7,01\text{pp}$) y Manhattan ($-8,61\text{pp}$).

Figura 43: Desviación respecto de la media para destino



Estos primeros resultados dan una idea sobre la distribución y características de los viajes que se identifican con cada clúster.

Los resultados se pueden comparar con los observados en la figura 22 y 23 de la sección 7.1 que son


usados como base de referencia para realizar estos cálculos. Los resultados numéricos están disponibles en sendas tablas en la sección de 11

Con lo anteriormente expuesto, se procede a realizar un análisis exploratorio para cada clúster en particular.

Análisis del clúster 0:

En el caso del clúster 0, se observa que agrupa aquellos viajes con una distancia recorrida en torno a las 7,6 millas y que suelen durar algo menos de 30 minutos con un coste alrededor de los \$29. Por las figuras 37, tenemos que los viajes son mayoritarios a partir del fin de semana, en especial los sábados. Y las franjas horarias que mejor representan estos viajes suelen ser mediada la tarde (a partir de las 18h alcanzan su pico). En cuanto a su característica geográfica, el 44,3% de los viajes parten de Manhattan (5,19pp más que la media de viajes que parten de allí), frente a un 25% de viajes desde Brooklyn y un 20% desde Queens (Ver figura 44 y tabla 13). Los destinos, como se comentó en párrafos anteriores, los destinos son similares respecto de la media, destacando Manhattan (35,8%), Brooklyn (25,22%) y Queens (21,33%)

Figura 44: Orígenes de trayecto clúster 0



PUBorough	Counts	Pct Counts (%)
Manhattan	2774	44.30
Brooklyn	1566	25.01
Queens	1294	20.69
Bronx	579	9.27
Staten Island	46	0.75
Out of City	1	0.02

Table 13: Distribución de viajes por borough de recogida en la muestra

Si se entra a mayor nivel de detalle, sobre las variaciones a nivel local las figuras 45 y 46) dan una idea general del comportamiento de los viajes que representan a este clúster y corroboran lo expuesto

y comentado a partir de las figuras 42 y 43.

Figura 45: Variación en puntos porcentuales de orígenes de trayectos para el clúster 0





Figura 46: Variación en puntos porcentuales de destinos de trayectos para el clúster 0




En la tabla 14 se muestran los principales trayectos para el clúster 0, aunque, como se indica, el porcentaje que los representa es marginal.

Origen (zona)	Destino (zona)	Pct Counts (%)
LaGuardia Airport	Out of City	0.43
JFK Airport	Out of City	0.38
Garment District	Out of City	0.24
Times Sq/Theatre District	LaGuardia Airport	0.18
LaGuardia Airport	Times Sq/Theatre District	0.16
West Chelsea/Hudson Yards	Out of City	0.16
Murray Hill	Out of City	0.14
West Village	Out of City	0.14
LaGuardia Airport	Midtown South	0.14
Midtown Center	Out of City	0.14

Table 14: Principales flujos de origen-destino dentro del Cluster 0

Pese haberse ofrecido los datos de números de viajes en valor absoluto, se ha considerado interesante conocer también la densidad de carreras FHV contratadas por localización. Para ello se toma el mapa de la figura 47 como ejemplo. En este caso, la densidad de taxis por milla cuadrada no supera los 180. En todos los clústeres, las zonas con mayor densidad se corresponden con Manhattan. Para más información, se pueden acceder a las tablas informativas en la sección de Anexos (11). En particular, para los viajes del clúster 0, Times Square se corresponde con la zona de la ciudad con más densidad de taxis.

Figura 47: Densidad de taxis para clúster 0




Con esta información sobre la mano, el clúster 0 se podría definir como viajes los fines de semana de vuelta a casa tras estar de compras por la zona de Times Square. A pesar también de incluir viajes desde los aeropuertos a las afueras de la ciudad. Representan el 31% de los viajes mensuales.

Análisis del clúster 1:

Para el caso del clúster 1, se tienen viajes cortos (2,4 millas), entre 10 y 12 minutos y con un precio en torno a los \$11,3. Suelen ser viajes sin peajes y sin extra de aeropuerto, lo que indica un menor número de viajes hacia éstos. De acuerdo con los patrones de hora y día de demanda de servicio FHV, destacan los fines de semana (especialmente los viernes) hacia horas de la noche (de las 20h en adelante). Por su parte, los viajes suelen partir de Manhattan (36,14%), con incrementos respecto de la media en Bronx (14,4%) y Brooklyn (27,1%) (ver la figura 48) con destinos similares en proporciones similares.

Figura 48: Número total de orígenes de trayecto para clúster 1



La variación a nivel local en puntos porcentuales para orígenes y destinos de trayectos pertenecientes al clúster 1 se muestran en las figuras 49 y 50 y corroboran lo expuesto anteriormente. Como añadido, las variaciones suelen ser pequeñas, o desde otro punto de vista, se asemejan más a la media total para cada localización (siendo evidente esto, debido a que se trata del clúster mayoritario).

Figura 49: Variación en puntos porcentuales de orígenes de trayectos para el clúster 1





Figura 50: Variación en puntos porcentuales de destinos de trayectos para el clúster 1



En cuanto a la densidad de taxis por milla cuadrada, es algo superior respecto al clúster 0, aunque se da en otras zonas de Manhattan (Se puede acceder a los resultados en la sección de Anexos, 11).

Los trayectos más comunes para el clúster 1 se muestran en la tabla 15:

Origen (zona)	Destino (zona)	Pct Counts (%)
East New York	East New York	0.59
Williamsburg (South Side)	Williamsburg (South Side)	0.35
Park Slope	Park Slope	0.31
Crown Heights North	Crown Heights North	0.26
Bedford-Stuyvesant West	Bedford-Stuyvesant West	0.23
East Flatbush/Farragut	East Flatbush/Farragut	0.22
Astoria	Astoria	0.20
Clinton Hill	Clinton Hill	0.19
East Flatbush/Rugby	Borough Park South	0.19
Canarsie	Greenpoint	0.18

Table 15: Principales flujos de origen-destino dentro del Cluster 1

En este caso, el clúster 1, que engloba el 61% de los viajes mensuales se puede caracterizar como "Viajes de regreso a casa tras una noche de ocio nocturno".

Análisis del clúster 2:

Por último, el clúster 2, que representa al 7% de los viajes mensuales, se caracteriza por incluir los viajes más largos (17,2 millas y más de una hora de viaje) y más costosos (\$63,2). Además, suelen tener un mayor recargo por peajes y trayectos hacia aeropuertos. Estas dos variables dan una idea sobre los orígenes y destinos de estos viajes.

Los viajes en este clúster suelen darse en días laborables (destacando miércoles, jueves y viernes) y, especialmente, en las horas de salida del trabajo (media tarde, entre las 15h y las 17h). Curiosamente, pese a representar el menor número de viajes, el patrón de comportamiento es el que más se asemeja a la media (ver figura 10 de la sección 7.1).

En cuanto a los viajes más comunes, destacan sobre todo aquellos que van a aeropuertos o afuera de la ciudad (ver tabla 16)


Origen (zona)	Destino (zona)	Pct Counts (%)
JFK Airport	Out of City	2.90
LaGuardia Airport	Out of City	2.09
JFK Airport	Times Sq/Theatre District	0.94
LaGuardia Airport	Times Sq/Theatre District	0.74
Times Sq/Theatre District	LaGuardia Airport	0.67
East Village	Out of City	0.67
Upper East Side South	Out of City	0.67
East Village	JFK Airport	0.54
East Harlem South	JFK Airport	0.54
Times Sq/Theatre District	JFK Airport	0.47

Table 16: Principales flujos de origen-destino dentro del Cluster 2

Sobre los orígenes de los trayectos, el clúster 2 se caracteriza por tener más viajes que parten de Manhattan (39,4%) y sobre todo de Queens (32,1%, muy por encima de su media habitual). Esto significa dos cosas: por un lado, Manhattan como centro financiero y de actividad económica general que refuerza la idea de gente saliendo del trabajo. Por el otro, que haya tantos viajes en Queens se

debe a la presencia de los aeropuertos -JFK, 12,9% de los viajes como punto de origen, LaGuardia, 8%- (ver figuras 51 y 52)

Figura 51: Número total de orígenes de trayecto para clúster 2



PUBorough	Counts	Pct Counts (%)
Manhattan	586	39.41
Queens	477	32.08
Brooklyn	311	20.91
Bronx	93	6.24
Staten Island	20	1.33

Table 17: Distribución de viajes por borough de recogida en el Cluster 2

Por su parte, en la tabla 18 se muestran los destinos más frecuentes de los viajes que caracterizan al clúster 2. En este caso, sí que destacan los aeropuertos, pero sobre todo aquellos que tienen como destino fuera de la ciudad.

Rank	DOL ^a	DOB ^b	Counts	Zone	Pct Counts (%)
1	265	Out of City	300	–	20.17
2	132	Queens	202	JFK Airport	13.58
3	1	EWB	67	Newark Airport	4.51
4	138	Queens	59	LaGuardia Airport	3.97
5	230	Manhattan	32	Times Sq/Theatre District	2.15

^a Localización destino (Drop-Off Location)

^b Distrito destino (Drop-Off Borough)

Table 18: Top 5 zonas de destino más frecuentes dentro del Cluster 2

El 26% de los viajes tienen como destino Manhattan (bastante por debajo de su media), siendo Queens (25,7%) y, sobre todo, 'Out of City' (20,2%) los que más suben (figura 53). Con estos datos, se podría caracterizar los viajes del clúster 2 como "salida del trabajo en sentido amplio". Es decir, por la hora y días, los destinos (zonas residenciales o suburbs anexos a la ciudad, aeropuertos) y la cuasi obligatoriedad de conducir por vías de alta capacidad o con destino alguno de los aeropuertos más próximos, parece plausible catalogar estos viajes de este modo.

Figura 52: Variación en puntos porcentuales de orígenes de trayectos para el clúster 2





Figura 53: Variación en puntos porcentuales de destinos de trayectos para el clúster 2



8 Diseño del Modelo

Esta sección describe el proceso seguido para la construcción del modelo de predicción desarrollado a partir de la muestra seleccionada. Se detallan las decisiones técnicas adoptadas en relación con la elección de variables, implementación del modelo de regresión, los procedimientos de validación y las comprobaciones estadísticas realizadas para garantizar la consistencia metodológica. El objetivo final es establecer una estructura robusta que permita estimar de forma precisa el valor de la variable objetivo ('driver pay') a partir de las características del viaje.

A partir de este punto, todos los modelos y evaluaciones se han realizado sobre la muestra de 20.000 observaciones seleccionada mediante muestreo aleatorio estratificado con semilla fija (random state = 42), correspondiente al mes de mayo de 2024. Se muestran las figuras 54 y 55 como ejemplo de selección particular.

Ejemplo del caso de uso de la iteración con random state = 42 para 20.000 observaciones aleatorias:

Figura 54: Distribución semanal de recogidas para la muestra aleatoria del random state 42






Figura 55: Distribución horaria de recogidas para la muestra aleatoria del random state 42



8.1 Selección de variables y estructura del modelo de predicción

Para el modelo de predicción, se estudió qué variables podían ser utilizadas como predictoras y, sobre todo, cuáles debían ser descartadas de entrada. La matriz de correlaciones de Pearson 56 sirvió de entrada para observar capacidades predictivas y posible colinealidad entre variables.

Figura 56: Matriz de correlación de Pearson



Por su parte, dada la naturaleza de la variable a predecir, se consideró excluir de partida una serie de variables: 'bcf', 'sales tax', 'tips' y 'base passenger fare'. Nótese que especialmente estas dos últimas ya quedan excluidas de la representación gráfica de la matriz de correlaciones.

Como se mencionó con anterioridad (5.2), 'base passenger fare' es el coste del viaje estimado por la compañía y que debe pagar el usuario. Dado su origen, urgía eliminarla del modelo para no contaminar, de ningún modo, la predicción de la variable objetivo.

Selección de la muestra

Tal y como se mencionó en la sección 6.6 y en el párrafo de introducción, para el modelo de predicción se utilizó una muestra aleatoria estratificada del conjunto de datos obtenida a partir de los resultados del clústering obtenido aplicando el algoritmo de K-Prototypes. Esto se hizo para poder incluir muestras representativas de los diferentes tipos de viajes identificados y asegurar la robustez y, minimizar en cualquier caso, el posible sesgo que pudiera incurrir un muestreo aleatorio común.

Las proporciones de cada clúster para la muestra fueron: 7% -para el clúster 2-, 30,5% -clúster 0- y 62,5%, clúster 1 (Véase la tabla 11 en la sección 7.4).

Feature selection

Por su parte, las propinas ('tips'), bcf (black car fund', similar a una seguridad social para conductores privados) o los impuestos ('sales tax') son recargos a posteriori de la carrera. Con lo cual, tendrán una alta correlación con la variable objetivo, pero poco sentido en términos de intentar anticipar el resultado desde un punto de vista de negocio. En estos casos, es más el sentido de negocio lo que las excluye del modelo, que el sentido estrictamente matemático.

Las variables 'trip miles' y 'trip time' se mantienen fijas en el modelo base debido a su fuerte relación con la variable objetivo y a su clara interpretabilidad en el contexto del negocio. Aunque presentan una correlación moderadamente alta entre sí (0,79), lo que podría sugerir cierto grado de colinealidad, ambas variables reflejan componentes fundamentales del cálculo del pago en los servicios de transporte, similares al funcionamiento de la tarifa tradicional de los taxis comunes (yellow taxis). Además, su inclusión permite construir un modelo sencillo, comprensible y alineado con la lógica económica del servicio prestado.

Variable objetivo: driver pay

Para este trabajo se ha escogido la variable 'driver pay' como variable objetivo del modelo de regresión. Desde el punto de vista técnico, se trata de una variable numérica continua, lo que la hace adecuada para técnicas de regresión lineal, entre otras. A nivel conceptual, 'driver pay' representa el importe que la compañía debe remunerar al conductor por cada trayecto con un mínimo de \$17,22/hora establecido por la Taxi and Limousine Commission (TLC) de la ciudad de Nueva York (New York City Taxi and Limousine Commission [2018b]).

En el contexto de negocio, modelar esta variable permite entender los factores que condicionan los ingresos de los conductores en servicios de alquiler de vehículos (HVFHVS), como Uber o Lyft, y sirve como base para estimar tarifas mínimas, evaluar eficiencia de rutas o detectar posibles anomalías en la remuneración.


Regresión Lineal por Mínimos Cuadrados

Tal y como se definió en la sección 6.5.2, se aplicó un modelo de regresión lineal por mínimos cuadrados para intentar predecir la remuneración del conductor.

Al modelo original basado en dos variables predictoras, se le buscaron alternativas de mejora. Como se irá desarrollando en la siguiente subsección, en un primer momento se encontró con un modelo con buenos resultados en cuanto a la predicción, pero la distribución de los residuos dejaba lugar a dudas sobre la posible existencia de variables (latentes o no) excluidas del modelo.

Por ejemplo, en la figura 57, se representan los precios predichos frente al error de predicción de cada entrada. Debido a la forma que tenía el gráfico de dispersión, se consideró la posibilidad de la existencia de una serie indeterminada de variables aún por incluir en el modelo:

Figura 57: Dispersión de residuos por tipo de 'shared request flag'



Dado que en un primer momento no estaba claro qué variables podían faltar en el modelo, se evaluó la inclusión de nuevas variables mediante técnicas de regularización L1 (Lasso), alternando con alternativas polinómicas y de grado uno. Uno de los resultados más destacables en términos de selección de variables fue el obtenido tras aplicar regularización L1 sobre un modelo de regresión de coeficientes lineales y un hiperplano definido por las variables: 'trip time', 'trip miles' y 'shared request flag' similar a lo mostrado en la gráfica de barras 58

Figura 58: Ejemplo de selección de variables por regularización L1





Figura 59: Dispersión de residuos por tipo de 'shared request flag' modelo de 3 variables



Pese a todo, tal y como se muestra en la figura 59, las mejoras fueron insuficientes.

8.2 Evaluación de los supuestos del modelo

Durante la fase del diseño, se exploraron distintas alternativas con el objetivo de mejorar la calidad estadística del modelo, en particular la distribución de los residuos y la validez de supuestos clásicos de regresión lineal. Se probaron alternativas como llevar a cabo transformaciones Box-Cox sobre la variable objetivo con la finalidad de aproximar a una distribución gaussiana de los errores. No obstante, los resultados obtenidos no supusieron mejoras significativas en la distribución de residuos, ni en los tests de normalidad. Además, en muchos casos, implicaron una pérdida sustancial en métricas clave como el coeficiente de R^2 o el error absoluto medio (MAE).

Justificación del uso de OLS/GLS (mínimos cuadrados)

En un principio, se optó por un modelo de regresión lineal estimado mediante el método de mínimos cuadrados ordinarios (OLS) por su sencillez, interpretabilidad, naturaleza del problema y transparencia en contextos de negocio. Dado además que la variable a predecir es numérica y continua, la técnica de mínimos cuadrados permite estimar de forma eficiente los coeficientes de un modelo lineal bajo ciertos supuestos (errores lineales, homocedásticos, independientes e idénticamente distribuidos (normales)).

En la tabla 19 se incluyen los principales estadísticos utilizados para evaluar la distribución de errores de acuerdo a los supuestos del modelo de regresión lineal clásico.

Table 19: Estadísticos de diagnóstico del modelo

Estadístico	Valor
Durbin-Watson	1.985
Jarque-Bera (JB)	1 555 384.292
Kurtosis	50.497
Skewness	4.390
Media de los residuos	5.33×10^{-16}
T-statistic (media = 0)	0.0000
p-value (media = 0)	1.0000
Breusch-Pagan (p-value)	2.84×10^{-136}

Justificación del uso de errores robustos (White-HC) si hay heterocedasticidad

El análisis de residuos reveló indicios claros de heterocedasticidad, confirmados mediante el test de Breusch-Pagan aplicado sobre el modelo de base y no normalidad de los mismos (test de Jarque-Bera y valores en la kurtosis y la asimetría o skewness, ver tabla 19). Si bien la heterocedasticidad no invalida la consistencia de los estimadores de mínimos cuadrados, sí afecta a la eficiencia de estos y, más importante aún, compromete la validez de las inferencias realizadas sobre los coeficientes de regresión. Los errores estándar convencionales podrían estar subestimados o sobreestimados, lo que alteraría los p-valores (y los intervalos de confianza).

Por este motivo, se optó por utilizar errores estándar robustos a la heterocedasticidad según el modelo de White (HC robust), que ajusta la matriz de varianzas y covarianzas de los estimadores sin modificar los coeficientes del modelo. Esto permite obtener inferencias válidas incluso si los residuos no presentan varianza constante. Es importante remarcar que este ajuste no corrige directamente la heterocedasticidad en los residuos, sino que compensa su efecto al nivel de inferencia.

Por otro lado, es importante distinguir entre errores y residuos: los errores representan las desviaciones reales respecto al modelo verdadero (teóricos), mientras que los residuos son estimaciones empíricas que no son independientes ni necesariamente normales. Por tanto, incluso si se asumiera normalidad en los errores, los residuos no cumplen esta condición estrictamente, lo que refuerza el uso de errores robustos en contextos reales.

8.3 Entrenamiento y validación del modelo

En esta subsección se describe el proceso de entrenamiento del modelo de regresión lineal, así como la metodología empleada para su validación. Se presentan las métricas utilizadas para evaluar el rendimiento tanto en el conjunto de entrenamiento como en el de prueba.

El modelo final diseñado consta de tres variables predictoras: 'trip miles', 'trip time' y 'shared request flag', seleccionadas por su relevancia tanto estadística como interpretativa en el contexto del negocio. El objetivo es predecir el valor de 'driver pay' mediante un modelo de regresión lineal, al que se le han aplicado errores estándar robustos (White-HC) para garantizar validez inferencial ante la presencia de heterocedasticidad en los residuos.

El conjunto de datos se dividió en un 80% para entrenamiento y un 20% para validación (tal y cómo se describió en 6.6), manteniendo la proporción de observaciones por clúster según la estratificación previa. A continuación (ver tabla 20), se presentan las métricas de evaluación obtenidas para ambos subconjuntos:


Table 20: Desempeño del modelo en los conjuntos de entrenamiento y de test

Conjunto	R^2	MAE (\$)	MAPE (%)
Train	0.949	2.13	12.17
Test	0.936	2.25	12.12

Interpretación de los errores del modelo

A continuación, en la figura 60 se presentan dos diagramas de dispersión que comparan los valores reales con los valores predichos por el modelo, tanto para el conjunto de entrenamiento como de test. La línea roja discontinua representa el ajuste perfecto (predicción = valor real), lo que permite observar de forma intuitiva la precisión y sesgo del modelo.

Figura 60: Conjuntos de entrenamiento y de test: valores reales frente a los predichos



Para evaluar los supuestos clásicos de la regresión lineal respecto a la distribución de los residuos, se incluyen una serie de representaciones gráficas. La primera, el gráfico QQ (figura 61) permite comprobar si los residuos se distribuyen según una normal teórica. Los otros dos gráficos (representados en la figura 62) muestran un gráfico de dispersión de los residuos frente a los valores predichos junto con el histograma de los residuos.

Figura 61: Diagrama QQ de distribución de residuos





Figura 62: Distribución de residuos



Estos gráficos son útiles para detectar patrones sistemáticos, asimetrías, posibles variables latentes y, sobre todo, posible presencia de heterocedasticidad. Estos últimos elementos son clave para valorar la validez estadística del modelo y justificar la necesidad de ajustar mediante errores robustos.

8.4 Interpretación del modelo lineal

La función de ajuste queda definida por:

$$\text{driver pay} = \text{Intercept} + \beta_1 \cdot \text{trip miles} + \beta_2 \cdot \text{trip time} + \beta_3 \cdot \text{shared request flag}$$

Los valores de los parámetros de ajuste estimados y los correspondientes estadísticos se recogen en la tabla 21

Table 21: Resultados del modelo de regresión con errores robustos (White-HC)

Variable	Coef.	Error Std.	Z	P>—z—	[0.025, 0.975]
Intercept	20.6313	0.031	666.977	0.000	[20.571, 20.692]
trip_miles	9.5841	0.156	61.346	0.000	[9.278, 9.890]
trip_time	8.2932	0.104	79.451	0.000	[8.089, 8.498]
shared_request_flag_1	-4.2726	0.241	-17.713	0.000	[-4.745, -3.800]

8.5 Generalización del modelo a otros meses

En esta subsección se analiza la capacidad del modelo para generalizar sobre datos no vistos. El objetivo es comprobar la fiabilidad de las predicciones obtenidas y la estabilidad del ajuste del modelo bajo distintos escenarios.

En la siguiente tabla (ver 22) se muestran los resultados tras generalizar a diversos meses del año 2024 con muestras de 20.000 observaciones escogidas mediante muestreo aleatorio estratificado para la regresión lineal:

Mes (2024)	Random State	R ²	MAE (\$)	MAPE (%)
Mayo (20K, aleatoria)	28	0.946	2.15	12.20
Enero (20K)	28	0.942	2.33	13.40
Marzo (20K)	28	0.949	2.03	12.00
Agosto (20K)	28	0.948	2.01	11.10
Septiembre (20K)	28	0.939	2.28	12.70
Diciembre (20K)	28	0.905	2.87	14.60

Table 22: Evaluación del modelo de regresión lineal sobre diferentes muestras mensuales de 2024 con sus respectivas semillas

A la vista de los resultados de generalización para otros meses mostrado en la tabla 22, el modelo generado con los datos de mayo de 2024 muestra una capacidad de generalización robusta. Solo en el mes de diciembre se observa una bajada de rendimiento a tener en cuenta. Quizá el hecho de ser una época de festividades y frío, influya en ello.

Los meses escogidos para la generalización pretenden representar distintas épocas del año: desde inviernos con días más cortos, meses de verano con posible gente de vacaciones, épocas con fiestas y meses de primavera y otoño.

8.6 Árboles de decisión como modelo alternativo

8.6.1 Descripción y motivación

Como se mencionó en la sección 6.5.3, se ha desarrollado un modelo de regresión basado en árboles de decisión como complemento al modelo de regresión lineal clásico. Este enfoque no paramétrico ofrece una alternativa robusta y flexible, capaz de capturar relaciones no lineales y manejar interacciones entre variables sin requerir supuestos estrictos sobre la distribución de los errores o la homocedasticidad de éstos. Además, los árboles de decisión, gracias a estar fundamentados en reglas de decisión, son altamente interpretables y facilitan la explicabilidad del modelo.

8.6.2 Ajuste del modelo y validación

Para entrenar el modelo de árbol de decisión, se volvió a emplear una muestra estratificada de 20.000 observaciones (como se explicó en 8.1). Esta se dividió en dos subconjuntos: uno de entrenamiento (con el 80% de los datos) y otro de test (el 20% restante). Las variables categóricas fueron transformadas mediante codificación one-hot (dummies) y se mantuvo el mismo criterio de división de datos utilizado en el modelo lineal.

Con el objetivo de obtener una configuración óptima del modelo y minimizar tanto el sobreajuste (overfitting) como la infraestimación (underfitting), se realizó un ajuste de hiperparámetros mediante una búsqueda mediante validación cruzada (GridSearchCV) con $k = 5$. En total, se evaluaron 1323 combinaciones posibles, utilizando el error absoluto medio negativo ('neg mean absolute error') como métrica de selección.

La combinación de hiperparámetros resultantes elegida fue:

- `max_depth = None`
- `min_samples_split = 5`
- `min_samples_leaf = 1`
- `max_features = None`

La evaluación del modelo entrenado con esta configuración arrojó un rendimiento que alcanzó el $R^2 = 0.993$ sobre el conjunto de entrenamiento, junto con un MAE de \$0.356 y un MAPE del 1,89% (Ver tabla 23). Sin embargo, se notó cierto overfitting en el árbol observándose cierta bajada en el rendimiento en test ($R^2 = 0.912$), MAE de \$2.163 y un MAPE de 10,52%. Pese a todo, los resultados siguen siendo competitivos frente al modelo lineal.

Table 23: Rendimiento del árbol de decisión (con hiperparámetros óptimos)

Conjunto	R^2	MAE (\$)	MAPE (%)
Entrenamiento	0.993	0.356	1.89
Prueba	0.912	2.163	10.52

8.6.3 Interpretación y comparación

Una de las principales ventajas que ofrecen los modelos de árbol de decisión es su interpretabilidad directa sobre la importancia de las variables predictoras. En este caso, el análisis de importancia de características revela que la variable con mayor peso en la predicción de 'driver pay' es claramente 'trip time' seguido por 'trip miles' (ver la figura 63). El resto de variables presentan contribuciones marginales (ver la tabla 24).

Figura 63: Importancia de las variables para el árbol de decisión





Table 24: Importancia de las variables en el modelo de árbol de decisión

Variable	Importancia (%)
trip_time	71.80
trip_miles	24.88
shared_match_flag_Y	0.38
tolls	0.12
wav_match_flag_Y	0.11

La visualización de los resultados muestra un buen ajuste general, con un diagrama de dispersión entre los valores reales y predichos por el modelo (figura 64) que confirma la capacidad del árbol para capturar la tendencia general del fenómeno. No obstante, se observan algunas dispersiones en los valores altos, donde la variabilidad es mayor.


Figura 64: Árbol de decisión: valores reales frente a predichos



El árbol obtenido se compone de un total de 15.273 nodos de los cuales, 7.637 son hojas y se registran 7.636 splits (internos). La figura 65 muestra los primeros niveles de división del árbol de decisión (con una profundidad máxima de 10 niveles).

Figura 65: Árbol de decisión

Visualización simplificada del árbol de decisión



Análisis de diferencias en desempeño o comportamiento respecto al modelo lineal

Comparado con el modelo de regresión lineal, el árbol de decisión ofrece un rendimiento similar en términos de MAE y R^2 en test. Quizá se observe una ligera pérdida de precisión en R^2 (0.91 vs 0.94 del modelo lineal). Sin embargo, el modelo de árbol de decisión gana en robustez a la hora de estimar errores, empezando porque ya no se requieren que se cumplan necesariamente los criterios de homocedasticidad o normalidad de éstos. Esto, junto su capacidad para modelar relaciones no lineales y captar interacciones complejas sin necesidad de transformaciones previas, lo convierte en una alternativa a la regresión lineal muy valiosa.

9 Conclusiones y trabajo futuro

A lo largo de este trabajo, se ha investigado el comportamiento de los viajes en servicios FHV en la ciudad de Nueva York y se han desarrollado modelos basados en conocimientos de ciencias de datos para la exploración, la segmentación y la predicción. Se han tratado aspectos clave desde el punto de vista técnico (preprocesamiento, análisis, modelado y validación) dando no sólo una perspectiva puramente técnica sino introduciendo aspectos teóricos sobre el sector de los servicios FHV en la ciudad de Nueva York.

En esta sección, se muestran los principales hallazgos del trabajo así como las limitaciones a las que ha tenido que enfrentarse el desarrollo del mismo. Por último, se proponen nuevas líneas de investigación futuras, desde la mejora y la evolución, a nuevos enfoques sobre problemas relacionados tanto con los servicios de alquiler de vehículos con conductor como de movilidad urbana.

9.1 Hallazgos relevantes

A partir del análisis realizado y los modelos desarrollados, se han obtenido una serie de observaciones que facilitan la comprensión del comportamiento de los viajes en servicios FHV en la ciudad de Nueva York:

- El modelo de predicción de la variable 'driver pay', referente a la remuneración del conductor, basado en regresión lineal, genera buenos resultados cuando se incluyen las variables de tiempo y distancia recorrida por carrera.
- Sin embargo, el modelo muestra cierta heterocedasticidad en los residuos, lo que motivó la aplicación de modelos robustos a errores, como el método de White (HC0).
- Los resultados del modelo lineal se generalizan correctamente para el resto de los meses analizados.
- Dado que se han recuperado los niveles de actividad previos a la pandemia, es plausible que esta generalización sea extensible para otros años sin alteraciones significativas en el patrón de movilidad.
- Se ha probado un modelo alternativo basado en árboles de decisión. Aunque muestra un ajuste ligeramente inferior al modelo lineal, confirma la influencia dominante de las variables 'trip time' y 'trip miles'.
- El análisis de segmentación (clustering) mediante el algoritmo K-Prototypes permitió identificar tres grandes tipos de viaje:
 - Un 61 % de viajes cortos que se producen mayoritariamente los fines de semana por la noche (relacionados con ocio nocturno).
 - Un 30 % de trayectos medios, en torno a las 7.5 millas, que suelen tener lugar los fines de semana por la tarde (posiblemente asociados a retornos a zonas residenciales tras visitas a Manhattan).
 - Un 7–8 % de trayectos largos, entre semana y en horas de salida del trabajo, muchos de ellos hacia los aeropuertos JFK o LaGuardia.
- Se ha analizado el comportamiento estadístico de distintas variables tanto numéricas como categóricas, y su impacto en el modelo y la movilidad urbana. Además, se han estudiado los patrones espaciales mediante mapas geográficos y la segmentación por compañía del sector.

- Finalmente, se ha demostrado que una muestra representativa de 20.000 observaciones, validada mediante técnicas de bootstrap, puede inferir de forma fiable las características de una población de más de 20 millones de viajes registrados por mes.

9.2 Limitaciones del trabajo

A pesar de los resultados obtenidos, el presente trabajo presenta una serie de limitaciones que conviene señalar para interpretar adecuadamente su alcance y sus conclusiones:

- Limitaciones técnicas (RAM, disco) que motivan la elección de métodos de inferencia estadística.
- Posible existencia de variables latentes o no observables dentro del modelo de regresión lineal.
- Variables asociadas a situaciones particulares (movilidad reducida, peajes, viajes al aeropuerto, etc.) difíciles de recoger en el modelo de regresión lineal.
- Dificultades a la hora de generalizar el árbol de decisión para diferentes meses a partir de un ajuste para un mes, debido a la presencia de diferentes variables de localización en diferentes meses.

9.3 Líneas de investigación futuras

A partir del desarrollo de este trabajo, se abren diversas líneas de investigación que pueden ser exploradas en estudios posteriores:

- Elaboración de un modelo predictivo para estimar 'driver pay' a partir del origen y destino del trayecto, de la franja horaria y del día de la semana.
- Estimación del margen de ganancia de una empresa a partir de la diferencia entre los ingresos estimados por carrera y la remuneración por carrera debida al conductor.
- Evaluación de la rentabilidad de una licencia FHV considerando que su coste aproximado es de \$380K USD por un periodo de dos años, y estimación del retorno de inversión en diferentes escenarios.
- Incorporación de variables exógenas como las condiciones atmosféricas (temperatura, humedad relativa, precipitación, etc.) para analizar su posible impacto en la naturaleza de los viajes.
- Exploración de otras técnicas avanzadas de ciencia de datos para la caracterización del sector de servicios FHV.

Agradecimientos

Agradezco el apoyo prestado por mi tutor de TFM, José Manuel Rodríguez Madrid, cuyos consejos y orientación me han permitido llevar a buen puerto este trabajo. Asimismo, quiero agradecer a todos los profesores del Máster Executive en Data Science, Big Data e Inteligencia Artificial de AFI por sus enseñanzas y su buena disposición para resolver cuantas dudas me han surgido a lo largo del curso. Y, por último quiero agradecer a mi hermano Javier, por sus consejos y aclaraciones de dudas sobre estadística, y a mis padres por el apoyo brindado durante la realización de este trabajo.

References

- Verra Mobility Corporation. 2024 urban mobility technology report. Technical report, Verra Mobility Corporation, June 2024. URL <https://www.verramobility.com/wp-content/uploads/2024/06/Verra-Mobility-UrbanMobilityTechSurvey-2024-vFF.pdf>. Accessed May 8, 2025.
- Emili Vizquete-Luciano, Miguel Guillén-Pujadas, David Alaminos, and José María Merigó-Lindahl. Taxi and urban mobility studies: A bibliometric analysis. *Transport Policy*, 133:144–155, 2023. ISSN 0967-070X. doi: <https://doi.org/10.1016/j.tranpol.2023.01.013>. URL <https://www.sciencedirect.com/science/article/pii/S0967070X23000197>.
- National Bureau of Economic Research. Transportation economics in the 21st century – for-hire vehicle data, February 2021. URL <https://www.nber.org/research/data/transportation-economics-21st-century-hire-vehicle-data>. Accessed May 5, 2025.
- Xinwu Qian, Tian Lei, Jiawei Xue, Zengxiang Lei, and Satish V. Ukkusuri. Impact of transportation network companies on urban congestion: Evidence from large-scale trajectory data. *Sustainable Cities and Society*, 55:102053, 2020. ISSN 2210-6707. doi: <https://doi.org/10.1016/j.scs.2020.102053>. URL <https://www.sciencedirect.com/science/article/pii/S2210670720300408>.
- Matthew Conway, Deborah Salon, and David King. Trends in taxi use and the advent of ridehailing, 1995–2017: Evidence from the us national household travel survey. *Urban Science*, 2:79, 08 2018a. doi: 10.3390/urbansci2030079.
- Transportation Research Board. Between public and private mobility: Examining the rise of technology-enabled transportation services. *TR News*, (302), May-Jun 2015. URL <https://onlinepubs.trb.org/onlinepubs/trnews/trnews302sr319.pdf>. Accessed May 5, 2025.
- David Schrank and Tim Lomax. The 2002 urban mobility report. Technical report, Texas Transportation Institute, The Texas A&M University System, jun 2002. URL https://rosap.ntl.bts.gov/view/dot/14544/dot_14544_DS1.pdf. Accessed May 5, 2025.
- David King, Matthew Wigginton Conway, and Deborah Salon. Do for-hire vehicles provide first mile/last mile access to transit? *Transport Findings*, 2020(May):1–7, 2020. doi: 10.32866/001c.12872. URL <https://doi.org/10.32866/001c.12872>.
- Yves Crozet. Cars and space consumption: Rethinking the regulation of urban mobility. Technical Report 2020/13, International Transport Forum, OECD Publishing, 2020. URL https://www.oecd.org/content/dam/oecd/en/publications/reports/2020/10/cars-and-space-consumption_34188fb4/8abaa384-en.pdf. Accessed May 5, 2025.
- Mitchell L. Moss and Hugh O’Neill. Urban mobility in the 21st century. Technical report, NYU Rudin Center for Transportation Policy and Management, November 2012. URL https://wagner.nyu.edu/files/rudincenter/NYU-BMWi-Project_Urban_Mobility_Report_November_2012.pdf. Accessed May 5, 2025.
- David Schrank, Bill Eisele, and Tim Lomax. 2019 urban mobility report. Technical report, Texas A&M Transportation Institute, August 2019. URL <https://static.tti.tamu.edu/tti.tamu.edu/documents/umr/archive/mobility-report-2019.pdf>. Accessed May 5, 2025.
- Matthew Conway, Deborah Salon, and David King. Trends in taxi use and the advent of ridehailing, 1995–2017: Evidence from the us national household travel survey. *Urban Science*, 2:79, 08 2018b. doi: 10.3390/urbansci2030079.
- Natashia Natashia and Shubashini Velu. Data exploratory on taxi data in new york city. 04 2020.

- Susan Shaheen, Adam Cohen, and Ismail Zohdy. Shared mobility: Current practices and guiding principles. Technical Report FHWA-HOP-16-022, United States Department of Transportation, Federal Highway Administration, apr 2016. URL <https://ops.fhwa.dot.gov/publications/fhwahop16022/fhwahop16022.pdf>. Accessed May 5, 2025.
- New York City Taxi and Limousine Commission and New York City Department of Transportation. Improving efficiency and managing growth in new york’s for-hire vehicle sector. Technical report, City of New York, June 2019. URL https://www.nyc.gov/assets/tlc/downloads/pdf/fhv_congestion_study_report.pdf. Accessed May 5, 2025.
- Aya Konishi, Vivek Ramakrishnan, Saba Waheed, and Lucero Herrera. Analysis of high volume for-hire vehicle data for new york city. selected months, 2019–2022. Technical report, UCLA Labor Center, February 2023. URL <https://www.labor.ucla.edu/wp-content/uploads/2023/02/Taxi-Commission-policy-brief-2.9.23.pdf>. Accessed May 5, 2025.
- David Schrank, Luke Albert, Kartikeya Jha, and Bill Eisele. 2023 urban mobility report. Technical report, Texas A&M Transportation Institute, The Texas A&M University System, jun 2024. URL <https://static.tti.tamu.edu/tti.tamu.edu/documents/mobility-report-2023.pdf>. Accessed May 5, 2025.
- Sam Schwartz Engineering. Taxi and for-hire vehicle study. Technical report, Los Angeles Department of Transportation, August 2019. URL https://ladot.lacity.gov/sites/default/files/documents/ladot-taxi-and-fhv-final-report-draft-for-distribution_0.pdf. Accessed May 5, 2025.
- Simran Borade, Kathleen Cohen, Chantal Davis, and Jake Stockman. Sustainable mobility in the united states: Challenges & opportunities from new technologies. Technical report, Heinrich Böll Foundation, dec 2020. URL <https://us.boell.org/sites/default/files/2020-12/Sustainable%20Mobility%20and%20Technology%20in%20the%20United%20States.pdf>. Accessed May 8, 2025.
- Federal Highway Administration. The transportation future: Trends, transportation, and travel. Technical report, U.S. Department of Transportation, Federal Highway Administration, Office of Transportation Policy Studies, dec 2020. URL https://www.fhwa.dot.gov/policy/otps/TPS_2020_Trends_Report.pdf. Accessed May 8, 2025.
- New York Dearest. What’s with the green taxis in nyc?, 2023. URL <https://newyorkdearest.com/green-taxis-nyc-cab/>. Accessed May 10, 2025.
- New York City Taxi and Limousine Commission. Tlc trip record data, 2025a. URL <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>. Accedido el 5 de mayo de 2025.
- New York City Taxi and Limousine Commission. Rules governing high-volume for-hire service providers, December 2018a. URL https://www.nyc.gov/assets/tlc/downloads/pdf/governing_hi_vol_service_providers_12_04_2018.pdf. Adopted December 4, 2018. Accessed May 5, 2025.
- New York City Taxi and Limousine Commission. Notice of promulgation of rules, June 2021. URL <https://www.nyc.gov/assets/tlc/downloads/pdf/notice-of-promulgation-of-rules-06-22-2021.pdf>. Dated June 22, 2021. Accessed May 5, 2025.
- New York City Taxi and Limousine Commission. Data dictionary – high volume fhv trip records, March 2025b. URL https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_hvfhs.pdf. Publicado el 18 de marzo de 2025. Accedido el 5 de mayo de 2025.

New York City Taxi and Limousine Commission. Driver income rules, December 2018b. URL https://www.nyc.gov/assets/tlc/downloads/pdf/driver_income_rules_12_04_2018.pdf. Adoptado el 4 de diciembre de 2018. Accedido el 5 de mayo de 2025.

Uber Technologies Inc. How rider prices and driver earnings work in an open marketplace — what moves us, 2021. URL <https://www.youtube.com/watch?v=r0Zo8LLzajQ>. Video publicado en YouTube. Accedido el 5 de mayo de 2025.

Date and time — representations for information interchange — part 1: Basic rules. Technical Report ISO 8601-1:2019, International Organization for Standardization, February 2019. URL <https://www.iso.org/standard/70907.html>. Accedido el 5 de mayo de 2025.

scikit-learn developers. *sklearn.covariance.EllipticEnvelope* — *scikit-learn Documentation*. scikit-learn, 2025. URL <https://scikit-learn.org/stable/modules/generated/sklearn.covariance.EllipticEnvelope.html>. Accessed on May 5, 2025.

Audhi Aprilliant. The k-prototype as clustering algorithm for mixed data type (categorical and numerical), January 2021. URL <https://towardsdatascience.com/the-k-prototype-as-clustering-algorithm-for-mixed-data-type-categorical-and-numerical-fe7c5>. Publicado en Towards Data Science.

kprototypes contributors. *kprototypes: Developer Interface Documentation*, 2025. URL <https://kprototypes.readthedocs.io/en/latest/api.html>. Accedido el 5 de mayo de 2025.

10 Glosario

TLC: Taxi and Limousine Commission, entidad perteneciente al gobierno de la ciudad de Nueva York encargada de regular y supervisar el transporte de pasajeros mediante vehículos contratados en Nueva York.

FHV: For-Hire Vehicle. Vehículo de alquiler con conductor. Equivalente a taxis, vehículos con licencia y solicitados por app.

HVFHV/HVFHVS: Categoría de servicios FHV regulada por la TLC para referirse a empresas del sector que operan con licencia, gestionan más de 10.000 viajes al día y utilizan plataformas digitales para conectar conductores con pasajeros.

PULocation: Pick-Up Location. Localización de origen o de recogida del pasajero que solicitó un viaje mediante app.

DOLocation: Drop-Off Location. Localización de destino del trayecto solicitado.

Ridehailing: servicio de viaje bajo demanda. Acción de un usuario que solicita un vehículo mediante una app para un viaje puntual.

Ridesourcing: servicio de movilidad intermediada por plataforma. Modelo en el que una plataforma digital conecta a conductores con pasajeros.

11 Anexos

Figura 66: Viajes con mismo origen y destino por distritos o boroughs




Figura 67: Top 30 de viajes con mismo origen y destino




Figura 68: Mapa con trayectos en la misma zona





Figura 69: Mapas con orígenes de trayecto por compañía



Clúster 0:


Rank	PULocationID	PUBorough	Counts	Zone	Counts (%)
1	138	Queens	222	LaGuardia Airport	3.55
2	132	Queens	143	JFK Airport	2.28
3	230	Manhattan	101	Times Sq/Theatre District	1.61
4	68	Manhattan	100	East Chelsea	1.60
5	161	Manhattan	92	Midtown Center	1.47
6	246	Manhattan	90	West Chelsea/Hudson Yards	1.44
7	231	Manhattan	84	TriBeCa/Civic Center	1.34
8	148	Manhattan	82	Lower East Side	1.31
9	164	Manhattan	80	Midtown South	1.28
10	234	Manhattan	79	Union Sq	1.26

Table 25: Top 10 zonas de recogida más frecuentes en la muestra analizada

Rank	DOLocationID	DOBorough	Counts	Zone	Counts (%)
1	265	Out of City	386	—	6.16
2	138	Queens	249	LaGuardia Airport	3.98
3	132	Queens	166	JFK Airport	2.65
4	1	EWB	90	Newark Airport	1.44
5	61	Brooklyn	89	Crown Heights North	1.42
6	230	Manhattan	88	Times Sq/Theatre District	1.41
7	181	Brooklyn	77	Park Slope	1.23
8	112	Brooklyn	76	Greenpoint	1.21
9	164	Manhattan	74	Midtown South	1.18
10	161	Manhattan	73	Midtown Center	1.17

Table 26: Top 10 zonas de destino más frecuentes en la muestra analizada

Figura 70: Densidad de taxis por destino de trayecto clúster 0



Zona (LocationID)	Borough	Counts	Shape Area (mi²)	Cab Density
Lenox Hill West (186)	Manhattan	66	0.3707	178.03
Times Sq/Theatre District (230)	Manhattan	88	0.5609	156.89
Midtown South (164)	Manhattan	74	0.5563	133.02
Murray Hill (163)	Manhattan	44	0.4086	107.69
Midtown North (162)	Manhattan	51	0.4789	106.49
Midtown Center (161)	Manhattan	73	0.7191	101.51
Lincoln Square East (261)	Manhattan	33	0.3434	96.09
Garment District (100)	Manhattan	34	0.3747	90.74
East Harlem South (114)	Manhattan	40	0.4702	85.07
Lower East Side (148)	Manhattan	59	0.6975	84.59

Table 27: Top 10 zonas por densidad de recogidas (cab density) en Manhattan

Clúster 1:


Rank	PULocationID	PUBorough	Counts	Zone	Pct Counts (%)
1	76	Brooklyn	172	East New York	1.38
2	61	Brooklyn	167	Crown Heights North	1.34
3	79	Manhattan	159	East Village	1.28
4	37	Brooklyn	146	Bushwick South	1.17
5	7	Queens	140	Astoria	1.12
6	231	Manhattan	133	TriBeCa/Civic Center	1.07
7	80	Brooklyn	133	East Williamsburg	1.07
8	161	Manhattan	125	Midtown Center	1.00
9	249	Manhattan	125	West Village	1.00
10	42	Manhattan	124	Central Harlem North	1.00

Table 28: Top 10 zonas de recogida más frecuentes (alternativo)

Rank	DOLocationID	DOBorough	Counts	Zone	Counts (%)
1	61	Brooklyn	185	Crown Heights North	1.49
2	265	Out of City	177	–	1.42
3	76	Brooklyn	153	East New York	1.23
4	246	Manhattan	146	West Chelsea/Hudson Yards	1.17
5	79	Manhattan	145	East Village	1.17
6	7	Queens	142	Astoria	1.14
7	231	Manhattan	137	TriBeCa/Civic Center	1.10
8	249	Manhattan	126	West Village	1.01
9	68	Manhattan	120	East Chelsea	0.96
10	181	Brooklyn	118	Park Slope	0.95

Table 29: Top 10 zonas de destino más frecuentes en la muestra analizada (actualizado)

Figura 71: Densidad de taxis por destino de trayecto clúster 1




Zona (LocationID)	Borough	Counts	Shape Area (mi ²)	Cab Density
Lenox Hill West (186)	Manhattan	108	0.3707	291.32
Midtown North (162)	Manhattan	102	0.4789	212.97
Upper West Side North (211)	Manhattan	78	0.3973	196.33
Murray Hill (163)	Manhattan	77	0.4086	188.46
Midtown South (164)	Manhattan	103	0.5563	185.15
East Harlem South (114)	Manhattan	84	0.4702	178.64
West Village (249)	Manhattan	126	0.7222	174.48
Gramercy (144)	Manhattan	79	0.4748	166.39
Times Sq/Theatre District (230)	Manhattan	93	0.5609	165.80
Union Sq (234)	Manhattan	118	0.7311	161.41

Table 30: Top 10 zonas por densidad de recogidas (cab density) en Manhattan

Clúster 2:


Figura 72: Densidad de taxis por destino de trayecto clúster 2



Zona (LocationID)	Borough	Counts	Shape Area (mi ²)	Cab Density
Times Sq/Theatre District (230)	Manhattan	32	0.5609	57.05
Garment District (100)	Manhattan	12	0.3747	32.03
Lenox Hill West (186)	Manhattan	11	0.3707	29.67
Murray Hill (163)	Manhattan	11	0.4086	26.92
Midtown Center (161)	Manhattan	19	0.7191	26.42
East Harlem North (87)	Manhattan	16	0.6721	23.81
Midtown South (164)	Manhattan	12	0.5563	21.57
Clinton East (48)	Manhattan	19	0.9425	20.16
East Chelsea (68)	Manhattan	18	1.1107	16.21
Upper West Side North (211)	Manhattan	6	0.3973	15.10

Table 31: Zonas con menor densidad de recogidas (cab density) en Manhattan

Figura 73: Bootstrap de clústeres por horas



PUBorough	Cluster 0	Cluster 1	Cluster 2
Bronx	-3.03	2.14	-6.02
Brooklyn	-1.10	0.96	-5.21
Manhattan	5.19	-2.97	0.28
Out of City	-0.00	0.00	NaN
Queens	-0.47	-0.41	10.94
Staten Island	-0.58	0.28	0.03

Table 32: Desviación porcentual de distribución por borough respecto a la media global, por clúster


DOBorough	Cluster 0	Cluster 1	Cluster 2
Bronx	-2.80	2.44	2.75
Brooklyn	-0.50	1.02	6.65
EWB	0.20	NaN	0.21
Manhattan	1.00	0.35	-8.60
Out of City	1.88	0.20	-0.64
Queens	0.52	-0.18	-0.01
Staten Island	0.08	-2.75	-0.18

Table 33: Desviación porcentual de distribución por borough de destino respecto a la media global, por clúster

Zona (LocationID)	Borough	Counts	Shape Area (mi ²)	Cab Density
Times Sq/Theatre District (230)	Manhattan	101	0.5609	180.06
Garment District (100)	Manhattan	61	0.3747	162.80
Murray Hill (163)	Manhattan	65	0.4086	159.09
Midtown South (164)	Manhattan	80	0.5563	143.80
Midtown North (162)	Manhattan	63	0.4789	131.54
Lenox Hill West (186)	Manhattan	48	0.3707	129.47
Midtown Center (161)	Manhattan	92	0.7191	127.93
Lincoln Square East (261)	Manhattan	41	0.3434	119.39
Lower East Side (148)	Manhattan	82	0.6975	117.56
Union Sq (234)	Manhattan	79	0.7311	108.06

Table 34: Top 10 zonas por densidad de recogidas (cab density) en Manhattan

Figura 74: Número total de viajes por destino de trayecto clúster 0




DOBorough	Counts	Pct Counts (%)
Manhattan	2243	35.80
Brooklyn	1577	25.22
Queens	1333	21.33
Bronx	580	9.30
Out of City	387	6.18
EWR	90	1.44
Staten Island	52	0.86

Table 35: Distribución de viajes por borough de destino en la muestra

PUBorough	Counts	Pct Counts (%)
Manhattan	4502	36.14
Brooklyn	3372	27.09
Queens	2581	20.72
Bronx	1795	14.43
Staten Island	199	1.60
Out of City	3	0.02

Table 36: Distribución actualizada de viajes por borough de recogida en la muestra


Figura 75: Número total de viajes por destino de trayecto clúster 1



DOBorough	Counts	Pct Counts (%)
Manhattan	4368	35.15
Brooklyn	3323	26.74
Queens	2566	20.63
Bronx	1803	14.54
Staten Island	197	1.55
Out of City	179	1.44

Table 37: Distribución actualizada de viajes por borough de destino en la muestra


Figura 76: Densidad de taxis por origen de trayecto clúster 1



Zona (LocationID)	Borough	Counts	Shape Area (mi ²)	Cab Density
Murray Hill (163)	Manhattan	93	0.4086	227.62
Times Sq/Theatre District (230)	Manhattan	117	0.5609	208.59
Lenox Hill West (186)	Manhattan	67	0.3707	180.72
Gramercy (144)	Manhattan	85	0.4748	179.03
Midtown North (162)	Manhattan	84	0.4789	175.39
Lower East Side (148)	Manhattan	122	0.6975	174.91
Midtown Center (161)	Manhattan	125	0.7191	173.82
West Village (249)	Manhattan	125	0.7222	173.09
Midtown South (164)	Manhattan	94	0.5563	168.97
Upper West Side North (211)	Manhattan	67	0.3973	168.64

Table 38: Top 10 zonas por densidad de recogidas (cab density) en Manhattan

Figura 77: Número total de viajes por destino de trayecto clúster 2




Rank	PULocationID	PUBorough	Counts	Zone	Counts (%)
1	132	Queens	192	JFK Airport	12.91
2	138	Queens	120	LaGuardia Airport	8.07
3	230	Manhattan	34	Times Sq/Theatre District	2.29
4	161	Manhattan	27	Midtown Center	1.82
5	246	Manhattan	27	West Chelsea/Hudson Yards	1.82
6	79	Manhattan	24	East Village	1.61
7	231	Manhattan	20	TriBeCa/Civic Center	1.34
8	237	Manhattan	20	Upper East Side South	1.34
9	100	Manhattan	19	Garment District	1.28
10	68	Manhattan	19	East Chelsea	1.28

Table 39: Top 10 zonas de recogida más frecuentes dentro del Cluster 2

Clúster 2:

Figura 78: Densidad de taxis por origen de trayecto clúster 1



Zona (LocationID)	Borough	Counts	Shape Area (mi²)	Cab Density
Times Sq/Theatre District (230)	Manhattan	34	0.5609	60.62
Garment District (100)	Manhattan	19	0.3747	50.71
Midtown Center (161)	Manhattan	27	0.7191	37.55
Lenox Hill West (186)	Manhattan	13	0.3707	35.07
Lincoln Square East (261)	Manhattan	12	0.3434	34.94
Murray Hill (163)	Manhattan	13	0.4086	31.82
East Harlem South (113)	Manhattan	18	0.5796	31.05
Midtown South (164)	Manhattan	17	0.5563	30.56
Midtown North (162)	Manhattan	14	0.4789	29.23
Yorkville West (170)	Manhattan	18	0.7432	24.22

Table 40: Zonas con menor densidad de recogidas (cab density) en Manhattan

DOBorough	Counts	Pct Counts (%)
Manhattan	390	26.20
Queens	382	25.71
Out of City	300	20.17
Brooklyn	279	18.75
EWB	67	4.51
Bronx	60	3.99
Staten Island	9	0.60

Table 41: Distribución de viajes por borough de destino en el Cluster 2